



## **SEGMENTASI SEMANTIK BERBASIS *DEEP LEARNING* UNTUK MENGIDENTIFIKASI GULMA PADA CITRA MULTISPEKTRAL *DRONE***

**FEBRI BAWAHIR**



**DEPARTEMEN ILMU KOMPUTER  
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM  
INSTITUT PERTANIAN BOGOR  
BOGOR  
2023**

- Hak Cipta Dilindungi Undang-undang  
1. Dilarang mengutip sebagian atau seluruh karya tulis ini tanpa mencantumkan dan menyebutkan sumber :  
a. Pengutipan hanya untuk kepentingan pendidikan, penelitian, penulisan karya ilmiah, penyusunan laporan, penulisan kritik atau tinjauan suatu masalah  
b. Pengutipan tidak merugikan kepentingan yang wajar IPB University.  
2. Dilarang mengumumkan dan memperbanyak sebagian atau seluruh karya tulis ini dalam bentuk apapun tanpa izin IPB University.



Hak Cipta Dilindungi Undang-undang

1. Dilarang mengutip sebagian atau seluruh karya tulis ini tanpa mencantumkan dan menyebutkan sumber :

- a. Pengutipan hanya untuk kepentingan pendidikan, penelitian, penulisan karya ilmiah, penyusunan laporan, penulisan kritik atau tinjauan suatu masalah
- b. Pengutipan tidak merugikan kepentingan yang wajar IPB University.

2. Dilarang mengumumkan dan memperbanyak sebagian atau seluruh karya tulis ini dalam bentuk apapun tanpa izin IPB University.



## **PERNYATAAN MENGENAI SKRIPSI DAN SUMBER INFORMASI SERTA PELIMPAHAN HAK CIPTA**

Dengan ini saya menyatakan bahwa skripsi dengan judul “Segmentasi Semantik Berbasis *Deep Learning* untuk Mengidentifikasi Gulma pada Citra Multispektral *Drone*” adalah karya saya dengan arahan dari dosen pembimbing dan belum diajukan dalam bentuk apa pun kepada perguruan tinggi mana pun. Sumber informasi yang berasal atau dikutip dari karya yang diterbitkan maupun tidak diterbitkan dari penulis lain telah disebutkan dalam teks dan dicantumkan dalam Daftar Pustaka di bagian akhir skripsi ini.

Dengan ini saya melimpahkan hak cipta dari karya tulis saya kepada Institut Pertanian Bogor.

Bogor, Agustus 2023

Febri Bawahir  
G64190096

Hak Cipta Dilindungi Undang-undang

1. Dilarang mengutip sebagian atau seluruh karya tulis ini tanpa mencantumkan dan menyebutkan sumber :
  - a. Pengutipan hanya untuk kepentingan pendidikan, penelitian, penulisan karya ilmiah, penyusunan laporan, penulisan kritik atau tinjauan suatu masalah
  - b. Pengutipan tidak merugikan kepentingan yang wajar IPB University.
2. Dilarang mengumumkan dan memperbanyak sebagian atau seluruh karya tulis ini dalam bentuk apapun tanpa izin IPB University.



Hak Cipta Dilindungi Undang-undang

1. Dilarang mengutip sebagian atau seluruh karya tulis ini tanpa mencantumkan dan menyebutkan sumber :
- a. Pengutipan hanya untuk kepentingan pendidikan, penelitian, penulisan karya ilmiah, penyusunan laporan, penulisan kritik atau tinjauan suatu masalah
- b. Pengutipan tidak merugikan kepentingan yang wajar IPB University.

## ABSTRAK

FEBRI BAWAHIR. Segmentasi Semantik Berbasis *Deep Learning* untuk Mengidentifikasi Gulma pada Citra Multispektral *Drone*. Dibimbing oleh YENI HERDIYENI.

Produksi karet di Indonesia memainkan peran penting dalam pendapatan devisa negara. Namun, pada tahun 2017-2021, industri karet di Indonesia menghadapi kesulitan akibat terjadi penurunan tingkat produksi sebesar 4,03% per tahun. Penyebab utama penurunan ini adalah serangan penyakit gugur daun karet yang disebabkan oleh patogen *Pestalotiopsis sp*. Pada perkebunan karet di Sembawa, terdapat beberapa bagian pohon karet yang telah mengalami defoliasi sehingga mengakibatkan pertumbuhan gulma di bawah pohon karet sakit. Pertumbuhan tersebut dapat mempengaruhi akurasi identifikasi kesehatan tanaman karet melalui remote sensing karena gulma memiliki warna visual yang serupa dengan tanaman karet sehat. Oleh karena itu, penelitian ini bertujuan untuk mengidentifikasi gulma guna membantu mengukur kesehatan tanaman karet secara tepat. Studi ini mengusulkan algoritma yang menggabungkan metode *k-means++ clustering* dan Segmentasi Semantik berbasis *deep learning* untuk mencapai segmentasi yang lebih akurat dan efisien dalam mengidentifikasi gulma. Algoritma yang diusulkan menunjukkan hasil yang menjanjikan dalam mengidentifikasi tanaman karet dan gulma dengan tingkat akurasi mencapai 95%.

Kata kunci: *deep learning*, gulma, *K-Means*, segmentasi semantik

## ABSTRACT

FEBRI BAWAHIR. Semantic Segmentation Based On Deep Learning for Identifying Weeds Using Drone Multispectral Imagery. Supervised by YENI HERDIYENI.

Rubber production in Indonesia plays an important role in the country's foreign exchange earnings. However, in 2017-2021, the rubber industry in Indonesia faced difficulties due to a decline in production levels of 4.03% per year. The main cause of this decline is the attack of rubber leaf fall disease caused by the pathogen *Pestalotiopsis sp*. In rubber plantations in Sembawa, there are several parts of rubber trees that have been defoliated, resulting in weed growth under diseased rubber trees. Such growth can affect the accuracy of rubber plant health identification through remote sensing because weeds have similar visual colors to healthy rubber plants. Therefore, this study aims to identify weeds to help measure the health of rubber trees precisely. This study proposes an algorithm that combines K-Means++ clustering and deep learning-based Semantic Segmentation methods to achieve more accurate and efficient segmentation in identifying weeds. The proposed algorithm shows promising results in identifying rubber plants and weeds with an accuracy rate of 95%.

*Keywords:* *deep learning*, *K-Means*, semantic segmentation, weed.



Hak Cipta Dilindungi Undang-undang

1. Dilarang mengutip sebagian atau seluruh karya tulis ini tanpa mencantumkan dan menyebutkan sumber :
- a. Pengutipan hanya untuk kepentingan pendidikan, penelitian, penulisan karya ilmiah, penyusunan laporan, penulisan kritik atau tinjauan suatu masalah.
- b. Pengutipan tidak merugikan kepentingan yang wajar IPB University.

2. Dilarang mengumumkan dan memperbanyak sebagian atau seluruh karya tulis ini dalam bentuk apapun tanpa izin IPB University.

© Hak Cipta milik IPB, tahun 2023<sup>1</sup>  
**Hak Cipta dilindungi Undang-Undang**

*Dilarang mengutip sebagian atau seluruh karya tulis ini tanpa mencantumkan atau menyebutkan sumbernya. Pengutipan hanya untuk kepentingan pendidikan, penelitian, penulisan karya ilmiah, penyusunan laporan, penulisan kritik, atau tinjauan suatu masalah, dan pengutipan tersebut tidak merugikan kepentingan IPB.*

*Dilarang mengumumkan dan memperbanyak sebagian atau seluruh karya tulis ini dalam bentuk apa pun tanpa izin IPB.*



**SEGMENTASI SEMANTIK BERBASIS *DEEP LEARNING*  
UNTUK MENGIDENTIFIKASI GULMA PADA CITRA  
MULTISPEKTRAL *DRONE***

**FEBRI BAWAHIR**

Skripsi  
sebagai salah satu syarat untuk memperoleh gelar  
Sarjana pada  
Program Studi Ilmu Komputer

- Hak Cipta Dilindungi Undang-undang  
1. Dilarang mengutip sebagian atau seluruh karya tulis ini tanpa mencantumkan dan menyebutkan sumber :  
a. Pengutipan hanya untuk kepentingan pendidikan, penelitian, penulisan karya ilmiah, penyusunan laporan, penulisan kritik atau tinjauan suatu masalah  
b. Pengutipan tidak merugikan kepentingan yang wajar IPB University.  
2. Dilarang mengumumkan dan memperbanyak sebagian atau seluruh karya tulis ini dalam bentuk apapun tanpa izin IPB University.

Tim Penguji pada Ujian Skripsi:

- 1 Dr. Aziz, S.Si., M.Kom.
- 2 Medria Kusuma Dewi Hardhienata, S.Komp., Ph.D.

Hak Cipta Dilindungi Undang-undang

1. Dilarang mengutip sebagian atau seluruh karya tulis ini tanpa mencantumkan dan menyebutkan sumber :

- a. Pengutipan hanya untuk kepentingan pendidikan, penelitian, penulisan karya ilmiah, penyusunan laporan, penulisan kritik atau tinjauan suatu masalah
- b. Pengutipan tidak merugikan kepentingan yang wajar IPB University.

2. Dilarang mengumumkan dan memperbanyak sebagian atau seluruh karya tulis ini dalam bentuk apapun tanpa izin IPB University.





Hak Cipta Dilindungi Undang-undang

1. Dilarang mengutip sebagian atau seluruh karya tulis ini tanpa mencantumkan dan menyebutkan sumber :

- a. Pengutipan hanya untuk kepentingan pendidikan, penelitian, penulisan karya ilmiah, penyusunan laporan, penulisan kritik atau tinjauan suatu masalah
- b. Pengutipan tidak merugikan kepentingan yang wajar IPB University.

2. Dilarang mengumumkan dan memperbanyak sebagian atau seluruh karya tulis ini dalam bentuk apapun tanpa izin IPB University.



Judul Skripsi : Segmentasi Semantik Berbasis *Deep Learning* untuk  
Mengidentifikasi Gulma pada Citra Multispektral *Drone*  
Nama : Febri Bawahir  
NIM : G64190096

Disetujui oleh

Pembimbing 1:  
Dr. Yeni Herdiyeni, S.Si., M.Kom.

---

Diketahui oleh

Ketua Departemen Ilmu Komputer:  
Dr. Sony Hartono Wijaya S.Kom., M.Kom.  
NIP. 19810809 200812 1 002

---

Tanggal Ujian:  
4 Agustus 2023

Tanggal Lulus:



## **PRAKATA**

Puji dan syukur penulis panjatkan kepada Allah subhanaahu wa ta'ala atas segala karunia-Nya sehingga karya ilmiah ini berhasil diselesaikan. Tema yang dipilih dalam penelitian yang dilaksanakan sejak bulan November 2022 sampai bulan Juli 2023 ini ialah pengidentifikasi gulma tanaman karet, dengan judul “Segmentasi Semantik Berbasis *Deep Learning* untuk Mengidentifikasi Gulma pada Citra Multispektral *Drone*”.

Terima kasih penulis ucapkan kepada pembimbing, Ibu Dr. Yeni Herdiyeni, S.Si., M.Kom. yang telah membimbing dan banyak memberi saran selama penelitian ini. Ucapan terima kasih juga disampaikan kepada Bapak Dr. Aziz, S.Si., M.Kom. dan Ibu Medria Kusuma Dewi Hardhienata, S.Komp., Ph.D. selaku dosen penguji yang telah memberikan masukan dan saran untuk menyempurnakan skripsi ini. Di samping itu, Ungkapan terima kasih juga disampaikan kepada kedua orang tua tercinta, Bapak Soderi dan Ibu Juleha serta seluruh keluarga dan teman-teman yang telah memberikan dukungan, doa, dan kasih sayangnya.

Semoga karya ilmiah ini bermanfaat bagi pihak yang membutuhkan dan bagi kemajuan ilmu pengetahuan.

Bogor, Agustus 2023

*Febri Bawahir*

Hak Cipta Dilindungi Undang-undang

1. Dilarang mengutip sebagian atau seluruh karya tulis ini tanpa mencantumkan dan menyebutkan sumber :
  - a. Pengutipan hanya untuk kepentingan pendidikan, penelitian, penulisan karya ilmiah, penyusunan laporan, penulisan kritik atau tinjauan suatu masalah
  - b. Pengutipan tidak merugikan kepentingan yang wajar IPB University.
2. Dilarang mengumumkan dan memperbanyak sebagian atau seluruh karya tulis ini dalam bentuk apapun tanpa izin IPB University.



DAFTAR TABEL	x
DAFTAR GAMBAR	x
DAFTAR LAMPIRAN	xi
I PENDAHULUAN	1
1.1 Latar Belakang	1
1.2 Rumusan Masalah	2
1.3 Tujuan	2
1.4 Manfaat	2
1.5 Ruang Lingkup	3
II TINJAUAN PUSTAKA	4
2.1 Tanaman Karet	4
2.2 Perkebunan Karet di Pusat Penelitian Karet Sembawa	4
2.3 Gulma	6
2.4 <i>K-Means++ Clustering</i>	7
2.5 U-Net	8
III METODE	10
3.1 Data Penelitian	10
3.2 Tahapan Penelitian	12
3.3 Lingkungan Pengembangan	17
IV HASIL DAN PEMBAHASAN	18
4.1 Akuisisi Data	18
4.2 Praproses Data	19
4.3 Dataset	26
4.4 Transformasi Warna	27
4.5 Segmentasi Semantik ( <i>Deep Learning</i> )	28
4.6 Implementasi Model	33
V SIMPULAN DAN SARAN	35
5.1 Simpulan	35
5.2 Saran	35
DAFTAR PUSTAKA	36
LAMPIRAN	38
RIWAYAT HIDUP	44



Lokasi pengambilan data di Pusat Penelitian Karet Sembawa	10
Band pada kamera multispektral <i>drone</i> DJI Phantom 4 Multispectral (DJI c2022)	11
Lokasi pengambilan data di Pusat Penelitian Karet Sembawa	18
Parameter <i>k-means++ clustering</i> untuk segmentasi	21
Hasil pengamatan setiap <i>cluster</i> terhadap objek secara visual	23
Penggabungan indeks <i>cluster</i> menjadi dua <i>cluster</i> yang disesuaikan	23
Metrik evaluasi identifikasi gulma pada citra perkebunan karet	30

## DAFTAR GAMBAR

1 Jarak tanam pada pohon karet (Bua 2022)	4
2 Daun karet yang terserang penyakit <i>Pestalotiopsis sp.</i> di Pusat Penelitian Karet Sembawa pada bulan Januari 2022 (Bua 2022)	5
3 Proses perubahan kerapatan kanopi tanaman karet secara alami dari bulan Juni-Okttober (Azizan <i>et al.</i> 2021)	6
4 Tingkat keparahan penyakit gugur daun karet oleh <i>Pestalotiopsis sp.</i> yaitu <i>resistant</i> (L0), <i>light infection</i> (L1), <i>moderate infection</i> (L2), <i>severe infection</i> (L3), dan <i>very severe</i> (L4) (Maryani dan Astuti 2019)	6
5 Kondisi tajuk pohon karet yang tipis dan gulma yang tumbuh di bawah pohon karet di Pusat Penelitian Karet Sembawa pada bulan Januari 2022 (Bua 2022)	7
6 Arsitektur U-Net (Ronneberger <i>et al.</i> 2015)	9
7 Peta lokasi pengambilan data di Pusat Penelitian Karet Sembawa (Bua 2022)	10
8 <i>Drone</i> DJI Phantom 4 Multispectral (DJI c2022)	11
9 Citra <i>hemispherical</i> dengan tingkat keparahan penyakit GDK (a) L1, (b) L2, (c) L3, dan (d) L4 (Dokumen pribadi 2022)	11
10 Diagram alir tahapan penelitian	12
11 (a) Ilustrasi ketinggian dan sudut kemiringan kamera <i>drone</i> dan (b) Ilustrasi <i>front overlap</i> dan <i>side overlap</i> pada pengambilan citra multispektral <i>drone</i> (Bua 2022)	13
12 Lokasi titik koordinat yang dipilih sebagai data <i>ground truth</i> pada lokasi Pengambilan 1 (a) BPM 24, (b) GT 1, dan (c) RRIC 100 dan Pengambilan 2 (d) BPM 24, (e) GT 1, dan (f) RRIC 100	18
13 Citra <i>orthomosaic</i> pada lokasi pengambilan 1 (a) BPM 24, (b) GT 1, dan (c) RRIC 100 dan pengambilan 2 (d) BPM 24, (e) GT 1, dan (f) RRIC 100	19
14 Citra <i>clipping orthomosaic</i> pada lokasi pengambilan 1 (a) BPM 24, (b) GT 1, dan (c) RRIC 100 dan pengambilan 2 (d) BPM 24, (e) GT 1, dan (f) RRIC 100	20

Hak Cipta Dilindungi Undang-undang  
1. Dilarang mengutip sebagian atau seluruh karya tulis ini tanpa mencantumkan dan menyebutkan sumber :

a. Pengutipan hanya untuk kepentingan pendidikan, penelitian, penulisan karya ilmiah, penyusunan laporan, penulisan kritik atau tinjauan suatu masalah.

b. Pengutipan tidak merugikan kepentingan yang wajar IPB University.

2. Dilarang mengumumkan dan memperbanyak sebagian atau seluruh karya tulis ini dalam bentuk apapun tanpa izin IPB University.



15	Objek (a) tanaman karet bagian tajuk atas, (b) tajuk bawah, (c) ranting, (d) tanah, dan (e) gulma pada perkebunan karet	21
16	Citra segmentasi RGB pada setiap cluster pengambilan 1 (a) BPM 24, (b) GT 1, dan (c) RRIC 100 dan pengambilan 2 (d) BPM 24, (e) GT 1, dan (f) RRIC 100	22
17	Hasil citra segmentasi RGB dari pendistribusian <i>cluster</i> menjadi dua cluster (a) tanaman karet dan (b) gulma	24
18	Titik koordinat ground truth yang akan dilakukan <i>clipping</i> (a) citra perkebunan karet dan (b) citra gulma	25
19	data citra (a) perkebunan karet dan (b) label gulma	27
20	Format warna (a) RGB dan (b) HSV	27
21	Model U-Net	28
22	Grafik (a) akurasi pelatihan dan validasi dan (b) loss pelatihan dan validasi	29
23	Citra pengujian model (a) citra asli dan (b) citra segmentasi gulma	29
24	<i>Confusion matrix</i> antara gulma dan non gulma	30
25	Evaluasi hasil segmentasi gulma pada citra perkebunan karet (a) citra asli, (b) citra segmentasi <i>k-means++ clustering</i> atau label gulma, (c) citra segmenetasi <i>k-means++ clustering</i> + semantik berbasis <i>deep learning</i> atau prediksi gulma, dan (d) perpotongan antara Gambar 25(b) dan Gambar 25(c)	31
26	Hasil segmentasi dari model yang berhasil diimplementasikan (a) segmentasi gulma dan (b) segmentasi tanaman karet	33

## DAFTAR LAMPIRAN

1	Hasil <i>masking</i> citra RGB <i>cluster</i> gulma pada setiap pengambilan dan lokasi	39
2	Hasil <i>masking</i> citra RGB <i>cluster</i> kebun karet pada setiap pengambilan dan lokasi	40
3	Evaluasi hasil segmentasi gulma dimana mulai sisi kiri merupakan citra asli (kebun karet), citra segmentasi <i>k-means++ clustering</i> , citra segmentasi <i>k-means++ clustering</i> + segmentasi semantik berbasis <i>deep learning</i> , dan perpotongan antara kedua metode segmentasi	41



Hak Cipta Dilindungi Undang-undang

1. Dilarang mengutip sebagian atau seluruh karya tulis ini tanpa mencantumkan dan menyebutkan sumber :

- a. Pengutipan hanya untuk kepentingan pendidikan, penelitian, penulisan karya ilmiah, penyusunan laporan, penulisan kritik atau tinjauan suatu masalah
- b. Pengutipan tidak merugikan kepentingan yang wajar IPB University.

2. Dilarang mengumumkan dan memperbanyak sebagian atau seluruh karya tulis ini dalam bentuk apapun tanpa izin IPB University.

## I PENDAHULUAN

### 1.1 Latar Belakang

Karet merupakan salah satu komoditas yang memiliki kontribusi signifikan terhadap devisa negara yang produksinya terkonsentrasi di Sumatera, khususnya di Sumatera Selatan, Sumatera Utara, Riau, dan Jambi (BPS 2020). Sekitar 80% produsen karet Indonesia masuk ke pasar ekspor, terutama pasar Amerika Serikat, Jepang, China, India, dan Korea (Nugroho *et al.* 2022; BPS 2020). Menurut data terbaru, karet di Indonesia telah menyumbang sebesar \$4,12 miliar, menjadikannya sebagai salah satu penyumbang devisa utama. Tidak hanya itu, Indonesia juga menempati peringkat kedua dalam produksi karet di dunia. Dalam satu tahun, jumlah produksi karet mencapai 3,12 Juta ton (Dekarindo 2021). Namun, sayangnya terdapat tren penurunan produksi sebesar 4,03% per tahun. fenomena tersebut berdampak negatif pada produktivitas karet di Indonesia yang mengalami penurunan sebesar 3,61% per tahun. Penurunan produktivitas ini kemudian berimbas pada penurunan kinerja ekspor karet sebesar 7,33% per tahun (Syarifa *et al.* 2023). Salah satu faktor utama yang menjadi penyebab penurunan ini adalah adanya kejadian penyakit tanaman karet yang melanda beberapa tahun belakangan ini.

Penyakit yang cukup umum pada tanaman karet adalah Gugur Daun Karet atau yang sering disingkat sebagai GDK. GDK disebabkan oleh patogen bernama *pestalotiopsis sp.* Gejala GDK pada tanaman karet dapat terlihat dengan adanya bintik-bintik coklat pada daun karet yang sudah tua (Maryani dan Astuti 2019). Akibat dari penyakit ini, kanopi tanaman karet dapat menjadi tipis dan mengalami defoliasi hingga 75-90% (Febbiyanti dan Fairuzah 2019). Dampak tersebut dapat berdampak negatif terhadap produktivitas dan kualitas karet yang dihasilkan. Pada perkebunan karet di Sembawa, terlihat beberapa bagian pohon karet mengalami defoliasi sehingga berakibat pada pertumbuhan gulma di bawahnya.

Keberadaan gulma memiliki beberapa konsekuensi yang perlu diperhatikan. Pertumbuhan gulma di perkebunan karet sering terjadi sebagai akibat dari adanya gugur daun karet yang mengakibatkan celah-celah ranting terbuka dan sinar matahari dapat menembus ke bawah. Hal ini menyebabkan gulma tumbuh subur di antara tanaman karet. Dampak dari penampakan gulma ini adalah tanaman karet yang mengalami gugur daun akan terlihat subur ketika diamati dari atas perkebunan. Perhatian terhadap masalah ini sangat penting karena penampilan visual tanaman karet yang sakit dapat terganggu oleh kehadiran gulma saat dilakukan identifikasi menggunakan metode *remote sensing*. Hal ini pada akhirnya mempengaruhi penilaian kesehatan tanaman karet karena karakteristik gulma mirip dengan tanaman karet sehat. Oleh karena itu, dalam upaya pengidentifikasi kesehatan tanaman karet yang lebih akurat dan efisien, penting untuk memperhatikan pertumbuhan gulma dan mengambil langkah-langkah untuk mengendalikannya. Langkah ini akan membantu mempertahankan proses identifikasi kesehatan tanaman yang lebih akurat dan efisien.

Pemantauan perkebunan karet konvensional merupakan kegiatan yang membutuhkan waktu dan tenaga yang cukup intensif (Azizan *et al.* 2021). Oleh karena itu, penting untuk menerapkan teknologi *remote sensing* guna memantau wabah penyakit daun karet secara efektif (ANRPC, 2020). Salah satu teknologi





yang dapat digunakan adalah penggunaan *drone* yang memiliki kemampuan secara efisien menyesuaikan perubahan lokasi dengan memanfaatkan peta dasar pertanahan yang praktis (Silalahi *et al.* 2021). Selain itu, keberadaan gulma juga perlu diperhatikan dalam pemantauan tanaman karet. Kesamaan karakteristik antara gulma dan tanaman karet sehat dapat mempengaruhi akurasi dalam pengidentifikasi kesehatan tanaman karet sakit (Bua 2022). Oleh karena itu, dalam pemantauan tanaman karet, penting untuk mengatasi tantangan yang muncul akibat keberadaan gulma tersebut.

Dalam pengidentifikasi gulma pada tanaman karet, Bua (2022) menggunakan metode *k-means++ clustering* pada citra perkebunan karet. Namun, masih terdapat beberapa komponen yang masih salah teridentifikasi. Penelitian terkait dengan gulma juga dilakukan oleh Sodjinou *et al.* (2021). Dalam penelitiannya, Sodjinou *et al.* menggunakan *dataset* sekunder berupa citra agronomis dengan format RGB yang diambil menggunakan kamera biasa. Sodjinou *et al.* mengusulkan pendekatan yang mengombinasikan algoritme segmentasi semantik dan *k-means clustering* untuk melakukan segmentasi tanaman dan gulma pada citra tersebut. Selain itu, Sodjinou *et al.* juga melakukan komparasi kinerja segmentasi dari algoritma yang diusulkan dengan algoritma *k-means clustering* dan *superpixel*. Hasil penelitiannya menunjukkan bahwa algoritme yang diusulkan mencapai tingkat akurasi tinggi yaitu sebesar 99,19%. Oleh karena itu, Dalam penelitian ini, akan diusulkan sebuah algoritme yang menggabungkan metode segmentasi berdasarkan kombinasi algoritme *k-means++ clustering* dan segmentasi semantik berbasis *deep learning* untuk melakukan segmentasi tanaman karet dan gulma secara lebih akurat dan efisien.

## 1.2 Rumusan Masalah

Berdasarkan latar belakang tersebut, maka penulis merumuskan masalah sebagai berikut:

- Bagaimana memperbaiki kekurangan pengidentifikasi gulma pada penelitian sebelumnya?
- Bagaimana cara menjelaskan karakteristik gulma dengan mengimplementasikan pemodelan *deep learning*?

## 1.3 Tujuan

Penelitian ini bertujuan untuk:

- Mengembangkan metode yang akurat untuk mengidentifikasi gulma guna membantu mengukur kesehatan tanaman karet secara tepat.
- Mengimplementasikan pemodelan *deep learning* untuk dapat menjelaskan karakteristik gulma berdasarkan fitur visual pada citra.
- Memperbaiki kekurangan pengidentifikasi gulma pada penelitian sebelumnya agar dapat mengenali gulma dan non-gulma dengan akurasi yang lebih tinggi.

## 1.4 Manfaat

Penelitian ini diharapkan dapat dimanfaatkan untuk:

- Memberikan hasil yang lebih andal dalam membedakan antara gulma dan non-gulma.
- Mengidentifikasi *level* kesehatan tanaman karet dapat dilakukan secara lebih akurat karena citra gulma dan non-gulma dapat teridentifikasi lebih baik.

- c Memudahkan *stakeholder* dalam mengawasi kesehatan tanaman karet sehingga dapat meminimalkan waktu, tenaga, dan biaya.

### **1.5 Ruang Lingkup**

Ruang lingkup pada penelitian ini adalah sebagai berikut:

- a Penelitian ini berfokus pada perkebunan karet yang terletak di Pusat Penelitian Karet Sembawa, Banyuasin, Sumatera Selatan.
- b Data diakuisisi pada tanggal 18-19 Januari dan 15-16 Juni 2022.
- c Data *ground truth* yang digunakan berupa data titik koordinat hasil dari pengambilan citra *hemispherical* yang akan digunakan oleh pakar, Tri Rapani Febbiyanti, untuk menilai *severity level* tanaman karet.



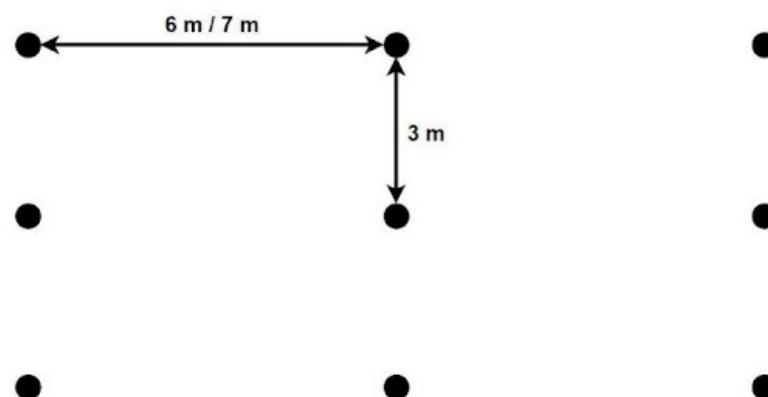
## 2.1 Tanaman Karet

Tanaman pohon kayu tropis yang dikenal sebagai karet (*Hevea brasiliensis*) adalah tanaman asli hutan hujan Amazon. Getah yang dihasilkan oleh pohon karet memiliki sifat unik, seperti elastis, tahan, dan tangguh (Payne 1962). Sifat-sifat istimewa ini yang menjadikan karet sebagai polimer yang sangat diandalkan dalam berbagai aplikasi baik dalam sektor transportasi seperti pembuatan ban, industri seperti lembaran silikon, konsumen seperti pakaian, maupun sektor medis seperti pipa dan kabel (Chen *et al.* 2018).

Peningkatan permintaan karet global menyebabkan meluasnya perkebunan karet di seluruh dunia secara bertahap, mulai dari 3 juta hektar pada tahun 1961 menjadi 12 juta hektar pada tahun 2019 (FAO 2021). Sekitar 9,2 juta hektar (78%) dari total karet ditanam di Asia Tenggara, sekitar 3,67 juta hektar (31%) berada di Indonesia dan 3,23 juta hektar (27%) berada di Thailand (FAO 2020). Hal tersebut menjadikan negara-negara di Asia memiliki pangsa kumulatif 73% dari produksi karet global (Nation Master 2021; Grow Asia 2021).

## 2.2 Perkebunan Karet di Pusat Penelitian Karet Sembawa

Pada tahun 1982, Pusat Penelitian Karet Sembawa memulai upaya pembukaan lahan dan penanaman tanaman karet. Kegiatan tersebut didedikasikan secara khusus untuk mengembangkan pengetahuan tentang tanaman karet melalui penelitian. Dalam penelitiannya, Pusat Penelitian Karet Sembawa menggunakan variasi jarak tanam 7x3 meter dan 6x3 meter (Sari dan Supijatno 2015). Gambar 1 mengilustrasikan jarak tanam pada pohon karet.



Gambar 1 Jarak tanam pada pohon karet (Bua 2022)

Perkebunan karet di Pusat Penelitian Karet Sembawa memiliki sejumlah jenis klon unggul dengan peran yang berbeda. Klon penghasil lateks terdapat IRR 104, IRR 112, IRR 118, IRR 220, BPM 24, PB 260, PB 330, dan PB 340. Sementara itu, klon penghasil lateks-kayu terdapat RRIC 100, IRR 5, IRR 39, IRR 42, IRR 107, dan IRR 119. Selain itu, perkebunan ini juga memiliki benih anjuran yang cocok untuk batang bawah yaitu AVROS 2037, GT 1, BPM 24, PB 260, RRIC 100, dan PB 330 (Hartawan 2012).

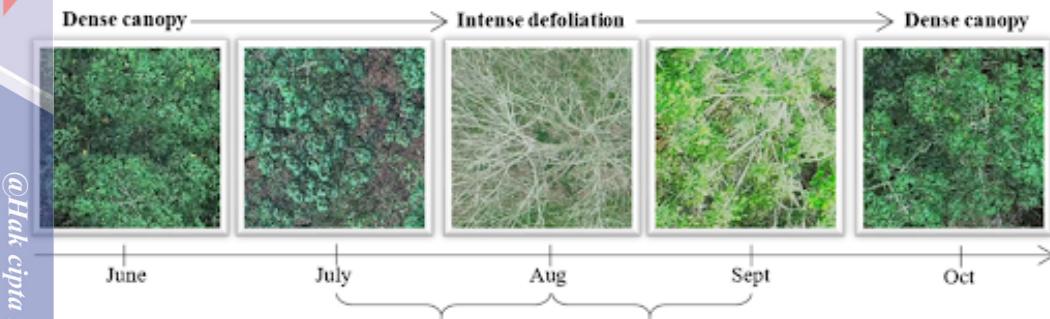
Lokasi perkebunan karet yang menjadi fokus penelitian ini mencakup tiga jenis klon, yaitu BPM 24, RRIC 100, dan GT 1. Klon BPM 24 merupakan hasil persilangan antara klon GT 1 dan AVROS 1734 yang berasal dari Indonesia. Sedangkan klon RRIC 100 merupakan hasil persilangan antara klon RRIC 52 dan PB 85 yang berasal dari Indonesia. Klon GT 1 adalah jenis klon lama yang menjadi tetua dalam proses persilangan buatan dan berasal dari Indonesia (Hartawan 2012).

Pada bulan Januari 2022, sekitar 500 hektar perkebunan karet di Pusat Penelitian Karet Sembawa hampir seluruhnya mengalami gugur daun karet (GDK) karena serangan patogen *Pestalotiopsis sp.* Yang menyerang daun seperti pada Gambar 2. Serangan tersebut menyebabkan daun berguguran sehingga kondisi tajuk pohon menjadi tipis, bahkan beberapa bagian perkebunan sudah terdampak parah sehingga hampir tidak terdapat daun sama sekali pada beberapa tajuk pohnnya. Kondisi tajuk yang tipis memiliki dampak yang cukup signifikan pada pertumbuhan gulma di antara tanaman karet. Situasi ini menimbulkan keprihatinan serius mengenai kelangsungan dan produktivitas perkebunan karet di perkebunan tersebut.



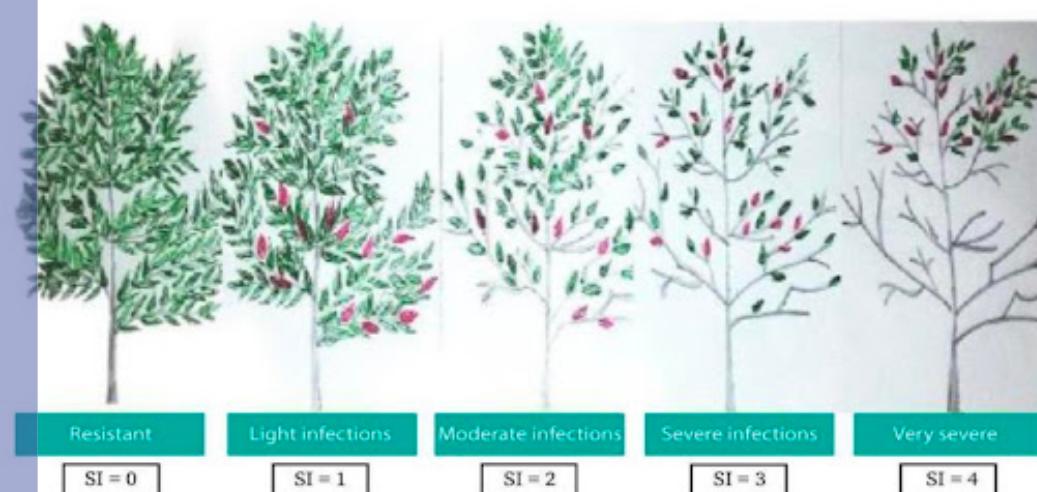
Gambar 2 Daun karet yang terserang penyakit *Pestalotiopsis sp.* di Pusat Penelitian Karet Sembawa pada bulan Januari 2022 (Bua 2022)

Tanaman karet mencapai kematangan dan siap untuk dipanen getahnya pada usia 5-7 tahun. Ketika mencapai tahap dewasa penuh, tanaman karet mengalami defoliasi selama bulan-bulan kering sebelum akhirnya mengganti daunnya dengan yang baru. Perubahan ini terjadi pada bulan Juli-Agustus, di mana daun yang semula hijau tua berubah menjadi coklat kekuningan selama hampir sebulan sebelum akhirnya berguguran yang menandakan berakhirnya musim tanam. Pada proses refoliasi sekitar Agustus-September, daun karet baru mulai muncul dan berkembang yang menandakan awal musim tanam yang baru (Azizan *et al.* 2021). Gambar 3 menggambarkan perubahan alami yang terjadi pada kerapatan kanopi tanaman karet.



Gambar 3 Proses perubahan kerapatan kanopi tanaman karet secara alami dari bulan Juni-Okttober (Azizan *et al.* 2021)

Penyakit gugur daun karet akibat penyakit *Pestalotiopsis sp.* sering terjadi saat mencapai puncak produksi getah karet setelah memasuki musim hujan, yakni dari Januari hingga Juni. Dampaknya, produksi getah karet menurun mulai dari November hingga Juni (Febbiyanti dan Fairuzah 2019). Pada bulan Oktober, daun karet sudah menunjukkan gejala penyakit namun belum terjadi gugur daun (*light infection*). Pada bulan November hingga Desember, tajuk pohon mulai gugur daun hingga 25% (*moderate infection*). Sementara itu, pada Januari hingga Maret, sebagian besar daun sudah terkena penyakit dan mengalami gugur hingga 26-75% (*severe infection*). Pada bulan April hingga Juni, seluruh daun pohon terkena penyakit dan tajuknya menipis drastis akibat gugur daun mencapai 76-100% (*very severe*) (Maryani dan Astuti, 2019; Kusdiana, 2021). Gambar 4 menampilkan tingkat keparahan penyakit gugur daun karet.



Gambar 4 Tingkat keparahan penyakit gugur daun karet oleh *Pestalotiopsis sp.* yaitu *resistant* (L0), *light infection* (L1), *moderate infection* (L2), *severe infection* (L3), dan *very severe* (L4) (Maryani dan Astuti 2019)

### 2.3 Gulma

Gulma adalah tanaman yang tidak diinginkan karena dapat bersaing dengan tanaman karet untuk mendapatkan air, nutrisi, cahaya, ruang, dan karbon dioksida yang sumber utamanya berasal dari tanah (Barba *et al.* 2020; Mahé *et al.* 2020;

Hasan *et al.* 2021). Keberadaan gulma di sekitar tanaman karet disebabkan oleh penceran sinar matahari yang menembus ke tanah melalui celah-celah ranting pohon karet yang telah gugur. Pada perkebunan karet di Pusat Penelitian Karet Sembawa, terdapat fenomena dimana gulma meningkat secara signifikan seiring dengan munculnya penyakit Gugur Daun Karet (GDK) yang menyerang tanaman karet seperti pada Gambar 5. Peningkatan gulma tersebut karena menipisnya tajuk pohon karet akibat serangan penyakit GDK. Kejadian tersebut menunjukkan adanya hubungan antara penyakit GDK dengan pertumbuhan gulma di perkebunan karet.



Gambar 5 Kondisi tajuk pohon karet yang tipis dan gulma yang tumbuh di bawah pohon karet di Pusat Penelitian Karet Sembawa pada bulan Januari 2022 (Bua 2022)

#### 2.4 *K-Means++ Clustering*

*K-means++ clustering* merupakan algoritme yang dikembangkan oleh Arthur dan Vassilvitskii pada tahun 2007. Algoritma *k-means++ clustering* merupakan hasil perbaikan dari *k-means clustering* standar yang telah dimodifikasi untuk mengatasi masalah *clustering* yang tidak optimal dalam algoritma. Perbedaan utama antara *k-means* standar dan *k-means++* terletak pada pemilihan *seed* sebagai titik pusat (*centroid*) awal. *k-means* standar memilih *seed* secara acak, sedangkan *k-means++* menggunakan pendekatan yang lebih cermat dalam pemilihan *seed* tersebut dengan mempertimbangkan jarak antar titik data. Algoritma *k-means++* terdiri dari beberapa tahapan sebagai berikut. (Arthur dan Vassilvitskii 2007).

- Pilih secara acak satu data  $x$  dari *dataset* sebagai *centroid*  $c_1$
- Tentukan jarak kuadrat antara setiap data  $x$  dalam *dataset* dan *centroid*  $c_1$  sebagai  $d(x_i, c_1)^2$  dengan  $i$  mempresentasikan setiap data  $x$ . Apabila terdapat beberapa *centroid*, cari nilai minimum dari  $d(x_i, c_j)^2$  di antara *centroid* yang telah ditentukan untuk setiap data  $x$  dengan  $j$  sebagai indeks *centroid*.
- Pilih *centroid* berikutnya ( $c_j$ ) dari data  $x$  dengan probabilitas jarak kuadrat yang tertinggi. Probabilitas jarak kuadrat dapat dihitung menggunakan persamaan (1) berikut (Arthur dan Vassilvitskii 2007):

$$P(d(x_i, c_j)^2) = \frac{d(x_i, c_j)^2}{\sum_{i=1}^n d(x_i, c_j)^2} \quad (1)$$

Keterangan:

- $P$  = probabilitas jarak kuadrat
- $d(x_i, c_j)^2$  = jarak kuadrat minimum antara data  $x_i$  dan *centroid*  $c_j$
- $i$  = urutan data  $x$  dari 1, 2, 3, ..., sampai  $n$
- $j$  = urutan *centroid* terpilih yang memiliki jarak kuadrat minimum terhadap  $x$
- $n$  = banyaknya data  $x$  dalam dataset, kecuali *centroid*

Lakukan iterasi tahap b hingga tercapai total *centroid* sebanyak  $k$ .

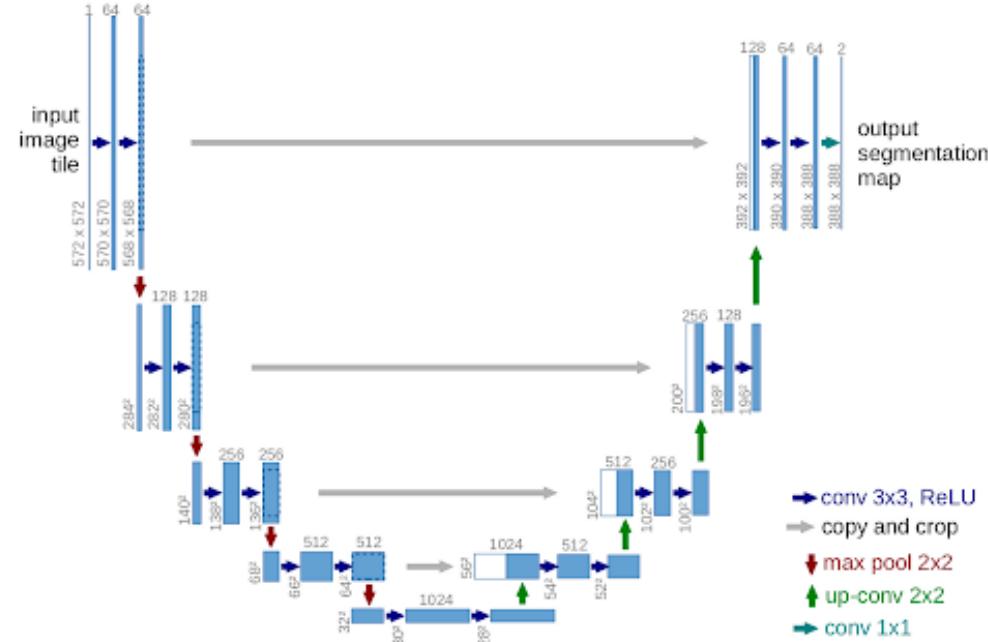
Setelah mendapatkan seluruh *centroid*  $c_j$  sampai  $k$  sebagai nilai awal (*seed*), lakukan langkah-langkah *clustering* seperti pada metode algoritme *k-means*.

Pendekatan pemilihan *seed* sebagai titik pusat (*centroid*) awal pada *k-means++* memberikan perbaikan yang cukup signifikan dalam mengurangi kesalahan akhir dibandingkan dengan *k-means* standar. Meskipun *k-means++* memerlukan banyak waktu untuk memilih *seed* sebagai titik pusat (*centroid*) awal, tetapi *k-means++* berjalan dengan cepat setelah tahapan tersebut sehingga dapat mempercepat waktu komputasi (Aubaidan *et al.* 2014). Oleh karena itu, pendekatan *k-means++* dapat dijadikan pilihan yang efektif dan efisien dalam proses *clustering*.

## 2.5 U-Net

U-Net adalah salah satu jenis arsitektur jaringan saraf tiruan yang sangat berguna dalam menangani tugas segmentasi citra. Arsitektur yang penamaannya diambil dari bentuk struktur jaringan yang menyerupai huruf U simetris ini, pertama kali dikembangkan pada tahun 2015 oleh Olaf Ronneberger, Philipp Fischer, dan Thomas Brox (Ronneberger *et al.* 2015). U-Net memiliki dua jalur yang dilakukan secara simetris yaitu jalur kontraksi (*encoding path*) atau *downsampling* yang berfungsi untuk mengekstraksi fitur-fitur penting dari citra dan jalur ekspansi (*decoding path*) atau *upsampling* yang membantu menghasilkan segmentasi yang lebih detail. Proses yang simetris pada kedua jalur tersebut menghasilkan representasi citra yang akurat dan konsisten. Kemampuan tersebut memungkinkan jaringan untuk mempelajari hubungan spasial antara objek-objek dalam citra dan menghasilkan segmentasi yang lebih tepat.

U-Net merupakan hasil pengembangan dari *Fully Convolutional Network* (FCN) yang telah dimodifikasi untuk mencapai performa segmentasi yang lebih unggul. Dua perbedaan mendasar antara U-Net dan FCN adalah U-Net memiliki struktur yang simetris dan menggunakan *skip connection* atau *concatenate* untuk menghubungkan jalur *downsampling* dan *upsampling* (Suta *et al.* 2020). Tujuan dari *skip connection* atau *concatenate* adalah untuk mentransfer informasi spasial dari *downsampling* ke *upsampling* secara *multilevel* guna menghasilkan segmentasi citra yang halus dan akurat (Hadinata *et al.* 2021). Gambar 6 menggambarkan arsitektur U-Net yang dibagi menjadi tiga bagian yaitu jalur kontraksi (*encoding path*) atau *downsampling*, *Bottleneck*, dan Jalur ekspansi (*decoding path*) atau *upsampling*.



Gambar 6 Arsitektur U-Net (Ronneberger *et al.* 2015)

Jalur kontraksi (*encoding path*) atau *downsampling* terdiri dari empat blok yang masing-masing blok terdiri dari dua *convolution layer* 3x3 dengan fungsi aktivasi dan proses *max pooling* 2x2. Sementara itu, *bottleneck* berperan sebagai penghubung antara proses *upsampling* dan *downsampling* yang dibangun dengan hanya 2 layer konvolusi yang dilengkapi *batch normalization*. Selain itu, jalur kontraksi (*encoding path*) atau *upsampling* terdiri dari empat blok yang masing-masing blok terdiri dari *Deconvolution layer* menggunakan 2 *stride*, penggabungan dengan *feature map* dari jalur *downsampling*, dan dua *convolution layer* berukuran 3x3 dengan fungsi aktivasi.

Fungsi aktivasi yang umum diaplikasikan pada U-Net adalah fungsi ReLU (*Rectified Linear Unit*). ReLU merupakan fungsi non-linear yang sederhana namun memiliki efektivitas tinggi dalam penggunaannya dalam jaringan saraf tiruan. Berikut merupakan formula dari aktivasi ReLU.

$$g(z) = \max \{0, z\} \quad (2)$$

Keterangan:

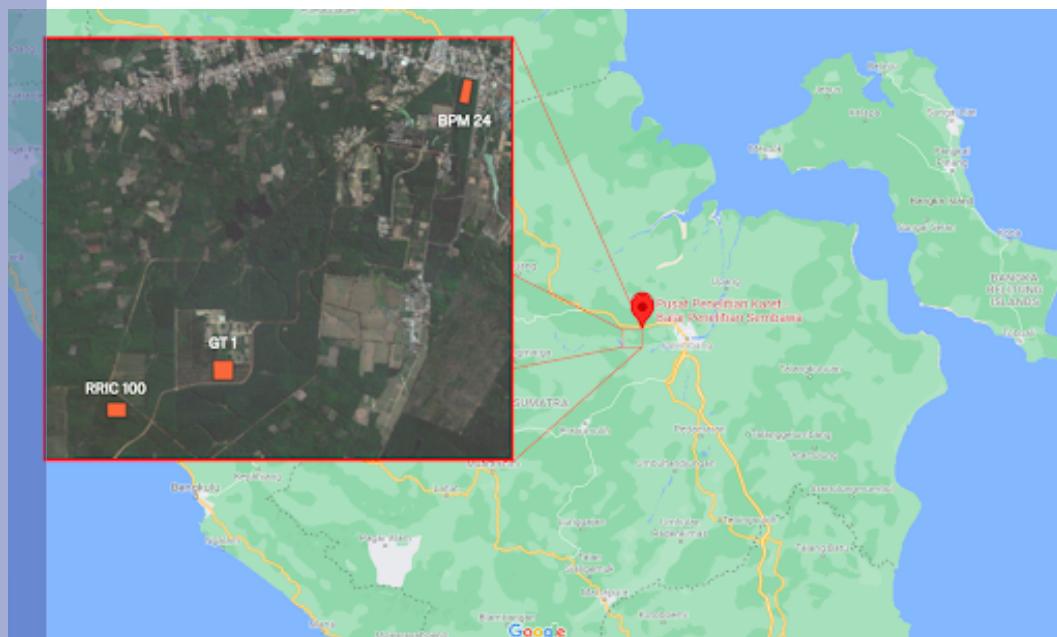
- $g(z)$  = nilai setelah aktivasi
- 0 = nilai batas ambang
- $z$  = nilai hasil konvolusi

### 3.1 Data Penelitian

Penelitian ini menggunakan data citra multispektral dan *ground truth* yang diperoleh dari Pusat Penelitian Karet Sembawa, Banyuasin, Sumatera Selatan. Pengambilan data dilakukan pada tanggal 18-19 Januari dan 15-16 Juni 2022 di tiga lokasi dengan jenis klon yang berbeda. Pemilihan lokasi dengan perbedaan klon tanaman bertujuan untuk mendapatkan data yang beragam sehingga memungkinkan perbandingan antara tanaman karet dan gulma. Data penelitian dapat dilihat pada Tabel 1 dan peta lokasi pengambilan data dapat dilihat pada Gambar 7.

Tabel 1 Lokasi pengambilan data di Pusat Penelitian Karet Sembawa

<b>Lokasi</b>	<b>Luas (m)</b>	<b>Titik Koordinat</b>	
		<i>Longitude</i>	<i>Latitude</i>
BPM 24	200 x 100	104,541644	-2,924831
RRIC 100	200 x 200	104,509275	-2,953957
GT 1	200 x 200	104,519218	-2,950331



Gambar 7 Peta lokasi pengambilan data di Pusat Penelitian Karet Sembawa, Banyuasin, Sumatera Selatan (Bua 2022)

Pengambilan citra multispektral dilakukan menggunakan *drone* DJI Phantom 4 Multispectral yang dilengkapi dengan D-RTK sebagai sistem *Global Positioning System* (GPS) untuk setiap tangkapan citra seperti yang diilustrasikan pada Gambar 8. *Drone* ini dilengkapi satu kamera sensor RGB dan lima kamera sensor

multispektral yang memiliki panjang gelombang yang berbeda sesuai dengan informasi pada Tabel 2.

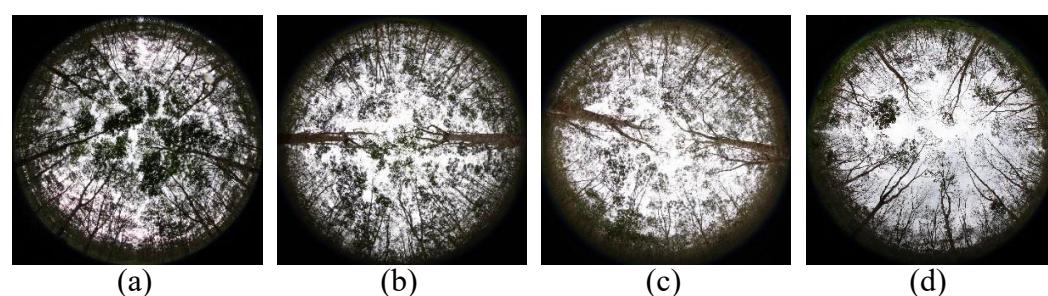


Gambar 8 *Drone* DJI Phantom 4 Multispectral (DJI c2022)

Tabel 2 *Band* pada kamera multispektral *drone* DJI Phantom 4 Multispectral (DJI c2022)

<b>Band</b>	<b>Center Wavelength (nm)</b>	<b>Wavelength Width (nm)</b>	<b>Wavelength Range (nm)</b>
Blue (B)	450	32	434 - 466
Green (G)	560	32	544 - 576
Red (R)	650	32	634 - 666
Red Edge (RE)	730	32	714 - 746
Near-infrared (NIR)	840	52	814 - 866

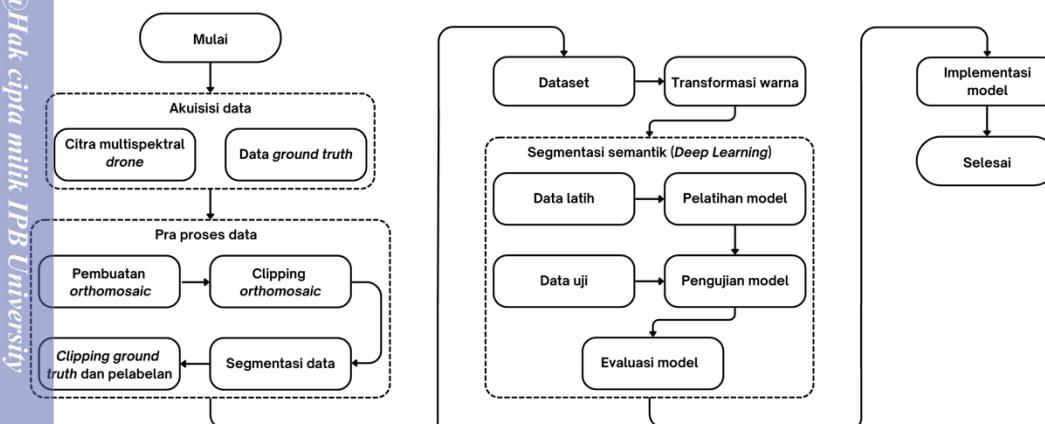
Data *ground truth* yang digunakan sebagai pembanding adalah data titik koordinat dengan tingkat keparahan (*severity level*) yang diperoleh melalui penilaian pakar tanaman karet, Tri Rapani Febbiyanti. Penilaian ini didasarkan pada pengamatan citra *hemispherical* yang diakuisisi pada tanggal yang sama dengan citra multispektral *drone*. Penggunaan citra *hemispherical* bertujuan untuk mengobservasi kerapatan tutupan tanaman dari bawah pohon. Contoh citra *hemispherical* dapat dilihat pada Gambar 9.



Gambar 9 Citra *hemispherical* dengan tingkat keparahan penyakit GDK (a) L1, (b) L2, (c) L3, dan (d) L4 (Dokumen pribadi 2022)

### 3.2 Tahapan Penelitian

Proses penelitian ini melibatkan beberapa tahapan, seperti akuisisi data, praproses data, transformasi warna, dan segmentasi semantik menggunakan *deep learning*. Gambar 10 menampilkan diagram aliran yang menjelaskan urutan langkah-langkah tersebut dalam proses penelitian.



Gambar 10 Diagram alir tahapan penelitian

#### 3.2.1 Akuisisi Data

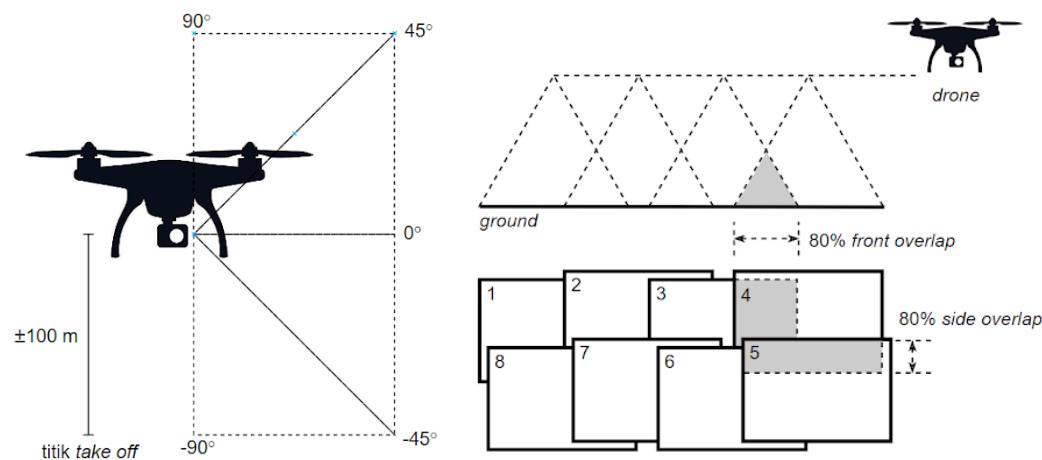
##### a) Citra Multispektral *Drone*

Kamera *drone* dilakukan penyesuaian untuk mendapatkan potongan citra yang lengkap dan dapat diproses secara menyeluruh. Sudut kemiringan kamera sebesar  $-90^\circ$  pada Gambar 11(a) menunjukkan bahwa kamera menghadap secara langsung ke bawah saat melakukan pengambilan citra dari ketinggian 100 meter di atas titik *take off*. Selain itu, penangkapan citra oleh kamera *drone* dilakukan dengan penyesuaian *overlap* yang tepat untuk memastikan penggabungan citra multispektral yang akurat. Gambar 11(b) mengilustrasikan penyetelan *front overlap* minimal 80% dan *side overlap* minimal 80%. Dalam konteks ini, saat kamera *drone* bergerak untuk mengambil citra baru, area yang sudah tercakup oleh citra sebelumnya harus tumpang tindih minimal 80% baik di bagian depan maupun samping citra yang akan diambil. Hasil penangkapan citra menggunakan kamera *drone* ini menghasilkan sekumpulan citra dengan sensor yang mencakup kanal RGB, biru (*blue*), hijau (*green*), merah (*red*), inframerah dekat (RE), dan inframerah jauh (NIR). Semua kanal ini penting dalam analisis multispektral untuk mendapatkan informasi yang lebih kaya tentang tanaman karet dan gulma.



Hak Cipta Dilindungi Undang-undang  
1. Dilarang mengutip sebagian atau seluruh karya tulis ini tanpa mencantumkan dan menyebutkan sumber :  
a. Pengutipan hanya untuk kepentingan pendidikan, penelitian, penulisan karya ilmiah, penyusunan laporan, penulisan kritik atau tinjauan suatu masalah  
b. Pengutipan tidak merugikan kepentingan yang wajar IPB University.

2. Dilarang mengumumkan dan memperbanyak sebagian atau seluruh karya tulis ini dalam bentuk apapun tanpa izin IPB University.



Gambar 11 (a) Ilustrasi ketinggian dan sudut kemiringan kamera *drone* dan (b) Ilustrasi *front overlap* dan *side overlap* pada pengambilan citra multispektral *drone* (Bua 2022)

Berdasarkan ketinggian pengambilan citra, diperoleh perkiraan *ground sample distance* (GSD) sebesar ( $\text{tinggi}/18,9$ ) cm/piksel (DJI c2022). GSD merupakan ukuran jarak antara titik tengah piksel atau resolusi piksel pada citra *drone*. Oleh karena itu, berdasarkan pengamatan kamera *drone*, diperoleh nilai GSD sebesar ( $100/18,9$ ) cm/piksel atau 5,29 cm/piksel. Setiap potongan citra memiliki jumlah piksel sebesar 1600 x 1300 piksel. Dengan demikian, setiap piksel pada citra tersebut mewakili area dengan ukuran 5,29 cm x 5,29 cm. Informasi ini menggambarkan resolusi spasial citra dan ukuran area yang diwakili oleh setiap piksel.

### b) Data *Ground Truth*

Pada tanggal yang sama dengan pengambilan data citra multispektral *drone*, dilakukan pengambilan data *ground truth*. Data *ground truth* terdiri dari tabel yang mencakup informasi seperti waktu akuisisi, nama file citra *hemispherical*, titik koordinat (*longitude* dan *latitude*), akurasi GPS, nama lokasi, dan tingkat keparahan yang dievaluasi oleh pakar tanaman karet. Data *ground truth* tersebut disimpan dalam format XLSX.

#### 3.2.2 Praproses Data

##### a) Pembuatan *Orthomosaic*

Perangkat lunak Agisoft Metashape Pro digunakan dalam proses pembuatan citra *orthomosaic*. Proses ini bertujuan untuk menggabungkan citra multispektral yang diambil secara terpisah oleh kamera *drone* menjadi citra *orthomosaic*. Kemudian, citra *orthomosaic* diunggah dalam format TIFF ke dalam asset GEE Code Editor. Format TIFF dipilih karena memberi performa yang lebih optimal untuk pengolahan citra dalam lingkungan GEE Code Editor.

##### b) *Clipping Orthomosaic*

Proses *clipping* pada citra *orthomosaic* diperlukan untuk menghapus objek-objek yang tidak relevan sehingga pengidentifikasi gulma tetap terfokus



pada area perkebunan karet. *Platform GEE Code Editor* digunakan untuk memangkas citra *orthomosaic* berdasarkan *Region of Interest* (ROI). ROI adalah area yang ditentukan untuk membatasi citra dan hanya mempertahankan objek di dalamnya. Proses *clipping* berdasarkan ROI akan menghasilkan citra *orthomosaic* yang terpotong hanya pada area perkebunan karet yang menjadi fokus utama dalam pengidentifikasiannya.

#### c) Segmentasi Data

Keberadaan gulma dalam citra perkebunan karet dapat menghambat pengidentifikasiannya. Kesehatan tanaman karet karena kemiripan karakteristik warnanya dengan tanaman karet sehat. Oleh karena itu, segmentasi citra *orthomosaic* diperlukan untuk memisahkan objek tanaman karet dan objek gulma. Pada platform GEE Code Editor, metode *k-means++ clustering* digunakan untuk melakukan segmentasi tersebut. Untuk meningkatkan akurasi pengukuran tingkat kesehatan taman karet, hasil segmentasi gulma akan digunakan sebagai label dalam proses identifikasi gulma lebih lanjut.

#### d) Clipping Ground Truth dan Pelabelan

Proses *clipping ground truth* dilakukan dengan menggunakan aplikasi QGIS. Proses ini bertujuan untuk mengumpulkan data berdasarkan titik koordinat pada citra *orthomosaic* yang akan digunakan sebagai dataset. Dalam proses *clipping*, digunakan *buffer radius* sebesar 4 meter. *Buffer radius* digunakan untuk memperluas area di sekitar titik koordinat yang diinginkan. Dengan melakukan *clipping* menggunakan *buffer radius*, citra yang diproyeksikan berada dalam jarak 10 meter dari titik koordinat tersebut akan dipertahankan.

Proses *clipping ground truth* melibatkan penggunaan dua jenis citra *orthomosaic*, yaitu citra *orthomosaic* asli dan citra *orthomosaic* gulma. Hasil *clipping* citra *orthomosaic* asli akan digunakan sebagai citra input, sedangkan hasil *clipping* citra *orthomosaic* gulma akan digunakan sebagai citra label. Setelah itu, citra-citra hasil *clipping* *orthomosaic* gulma akan diubah menjadi format warna biner (hitam dan putih) menggunakan fungsi dari *library OpenCV* pada *platform Google Colab*.

#### 3.2.3 Dataset

Setelah proses *clipping* dan pelabelan, citra asli dan citra label akan disimpan dalam dataset. Dataset ini akan digunakan sebagai *input* data dalam proses segmentasi semantik berbasis *deep learning*. Dengan memanfaatkan dataset tersebut, model *deep learning* dapat dilatih untuk mengidentifikasi dan memisahkan objek gulma dari citra asli.

#### 3.2.4 Transformasi Warna

Pada *platform Google Colab*, citra RGB akan diubah ke dalam format warna HSV dengan menggunakan fungsi yang terdapat dalam *library OpenCV*. Konversi ini memungkinkan manipulasi komponen warna secara lebih fleksibel dan operasi pengolahan citra yang lebih spesifik dalam deteksi objek gulma. Hal ini membantu meningkatkan kualitas dan keakuratan dalam proses identifikasi objek gulma. Ruang warna HSV memiliki keunggulan dalam memisahkan komponen warna dalam citra. Komponen Hue merepresentasikan informasi

warna, komponen Saturation menggambarkan kecerahan warna, dan komponen Value mengindikasikan intensitas kecerahan. Dengan memanfaatkan ruang warna HSV, diharapkan identifikasi objek gulma dapat dilakukan dengan lebih efektif.

### 3.2.5 Segmentasi Semantik (*Deep Learning*)

#### a) Data Latih dan Data Uji

Pada proses penggunaan *deep learning*, terdapat dua jenis data yang digunakan, yaitu data latih dan data uji. Data latih digunakan untuk melatih model, sementara data uji digunakan untuk menguji keakuratan dan performa model yang telah dilatih. Pembagian data tersebut dilakukan secara acak dengan proporsi 70% data latih dan 30% data uji. Metode pembagian acak ini digunakan untuk memastikan bahwa model yang dikembangkan dapat diuji secara objektif dan independen. Dengan demikian, pendekatan ini membantu menghindari bias yang mungkin muncul jika data latih dan data uji tidak dilakukan secara acak. Selain itu, untuk memastikan kesesuaian dengan model *input* pada proses *deep learning*, kedua jenis data tersebut akan diubah ukurannya menjadi 128x128 piksel. Hal ini dilakukan agar data latih dan data uji sesuai dengan format *input* yang dibutuhkan oleh model dalam proses *deep learning*.

#### b) Pelatihan Model

Arsitektur U-Net akan menjadi dasar yang kokoh dalam pelatihan model dan penyesuaian arsitektur diperlukan untuk mengoptimalkan hasil segmentasi semantik berbasis *deep learning*. Arsitektur U-Net akan dikembangkan berdasarkan studi literatur yang relevan berdasarkan topik penelitian. Selain itu, model tersebut akan disesuaikan dengan kebutuhan dan karakteristik khusus dari dataset yang akan digunakan.

#### c) Pengujian Model

Setelah melalui proses pelatihan menggunakan data latih, model tersebut kemudian diuji menggunakan data uji untuk memvalidasi dan mengevaluasi performa model dalam memprediksi objek gulma pada citra asli. Pengujian model memiliki peran yang signifikan dalam menilai kualitas dan keandalan model. Hasil pengujian ini akan menjadi dasar penilaian untuk mengevaluasi kemampuan model dalam mengidentifikasi gulma pada citra asli.

#### d) Evaluasi Model

Evaluasi model merupakan tahapan penting yang dilakukan setelah pengujian model untuk menilai efektivitas dan keberhasilan model yang digunakan. Tujuan evaluasi model adalah untuk mengukur sejauh mana model mampu melakukan prediksi gulma secara akurat dan memahami kualitas dari prediksi yang dihasilkan. Dalam proses evaluasi, digunakan seperangkat matriks yang sesuai untuk memberikan gambaran yang komprehensif tentang performa model. Beberapa matriks yang digunakan dalam evaluasi model adalah sebagai berikut:

##### (1) *Confusion Matrix*



*Confusion Matrix* digunakan untuk mengevaluasi performa model dengan membandingkan prediksi model dengan nilai sebenarnya pada data uji. *Confusion Matrix* terdiri dari empat kondisi utama yang merangkum jumlah prediksi yang benar dan salah. Dengan menggunakan nilai hitungan, maka dapat diketahui empat kondisi tersebut, yaitu:

- *True Positive* (TP): Jumlah sampel positif yang diprediksi dengan benar.
- *True Negative* (TN): Jumlah sampel negatif yang diprediksi dengan benar.
- *False Positive* (FP): Jumlah sampel negatif yang salah diprediksi sebagai positif (kesalahan Type I).
- *False Negative* (FN): Jumlah sampel positif yang salah diprediksi sebagai negatif (kesalahan Type II).

Dengan empat nilai ini, maka dapat dievaluasi kinerja model secara lebih terperinci, seperti *accuracy*, *precision*, *recall*, dan *F1-score*. *Confusion Matrix* membantu dalam memberikan gambaran yang lebih komprehensif tentang kekuatan dan kelemahan model yang sedang dievaluasi. Semakin tinggi kejelasan dan kelengkapan dalam menginterpretasi hasil evaluasi, semakin dapat dipercaya dan akurat hasilnya untuk membuat keputusan lebih tepat.

### (2) Accuracy

*Accuracy* adalah ukuran keberhasilan prediksi yang tepat dari pengklasifikasi terhadap seluruh prediksi yang dilakukan. Lebih spesifiknya, *accuracy* menggambarkan rasio antara jumlah sampel yang diprediksi benar dari seluruh sampel yang ada dalam dataset (Chicco dan Jurman 2020). *Accuracy* dapat dilihat pada persamaan (3).

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN} \quad (3)$$

### (3) Precision

*Precision* merepresentasikan proporsi sampel positif yang diprediksi benar terhadap total sampel yang diprediksi positif (Sokolova *et al.* 2006). Dalam konteks evaluasi model klasifikasi, *precision* adalah ukuran penting yang menggambarkan sejauh mana model dapat mengidentifikasi dengan tepat kelas positif. *Precision* dapat dilihat pada persamaan (4).

$$\text{Precision} = \frac{TP}{TP + FP} \quad (4)$$

### (4) Recall

*Recall* didefinisikan sebagai sampel positif yang diprediksi benar terhadap jumlah total sampel positif (Sokolova *et al.* 2006). Dalam istilah yang lebih sederhana, *recall* mengukur kemampuan model untuk menemukan kembali atau mengidentifikasi semua kasus positif yang ada dalam dataset. *Recall* dapat dilihat pada persamaan (5).



$$Recall = \frac{TP}{TP + FN} \quad (5)$$

### (5) F1-score

F1-score didefinisikan sebagai rata-rata *precision* dan *recall* yang harmonis (Chico dan Jurman 2020). Artinya, ketika nilai *recall* meningkat maka nilai *precision* akan menurun, begitu juga sebaliknya. Persamaan dari *F1-score* dapat dilihat pada persamaan (6).

$$F1 - score = 2 \times \frac{Precision \times Recall}{Precision + Recall} \quad (6)$$

#### 3.2.6 Implementasi Model

Dalam implementasi model, citra *orthomosaic* berukuran besar akan dipecah menjadi sejumlah citra kecil dengan ukuran yang sama. Langkah ini dilakukan untuk memudahkan pemrosesan karena citra berukuran besar dapat menjadi kompleks dan memakan waktu untuk dianalisis secara keseluruhan. Setelah pembagian citra, kumpulan citra kecil tersebut akan diubah dari format warna RGB menjadi format warna HSV (*Hue, Saturation, Value*). Pengubahan format warna ini dapat memberikan keuntungan dalam mengidentifikasi perbedaan tingkat warna yang lebih jelas dan mudah untuk diekstraksi.

Selanjutnya, kumpulan citra dalam format warna HSV akan digunakan sebagai *input* untuk model U-Net yang telah dibuat sebelumnya. Model U-Net akan memproses setiap citra kecil dan menghasilkan *output* berupa label “gulma”. Setelah gulma berhasil diprediksi, label hasil prediksi dari setiap citra kecil akan digabungkan kembali untuk mengembalikan ukuran citra seperti ukuran citra semula. Proses penggabungan ini juga mencakup pengaturan kembali posisi kumpulan citra kecil terhadap citra semula.

Kemudian label “tanaman karet” atau “non-gulma” akan dibuat berdasarkan kebalikan dari label “gulma” menggunakan operasi *bitwise and* pada *library* OpenCV. Setelah itu, citra *orthomosaic* dilakukan masking menggunakan label yang telah dihasilkan. Hasil segmentasi citra *orthomosaic* “tanaman karet” atau “non gulma” akan digunakan untuk mengidentifikasi tingkat keparahan penyakit tanaman karet.

### 3.3 Lingkungan Pengembangan

Spesifikasi perangkat keras dan perangkat lunak yang digunakan pada penelitian ini adalah sebagai berikut:

- a Perangkat perangkat keras berupa komputer personal dengan spesifikasi:
  - 1) Processor Chip Apple M1 Pro 8-Core CPU, 14-CoreGPU, 16GB RAM, 512 GB SSD
- b Perangkat lunak yang digunakan:
  - 1) Sistem Operasi macOS Monterey version 12.5.1
  - 2) Agisoft Metashape Pro 1.8.4 untuk praproses data
  - 3) Google Earth Engine (GEE) Code Editor sebagai integrated development environment (IDE)
  - 4) Google Sheet untuk visualisasi data
  - 5) Google Colab sebagai integrated development environment (IDE)

## 4.1 Akuisisi Data

### 4.1.1 Citra Multispektral *Drone*

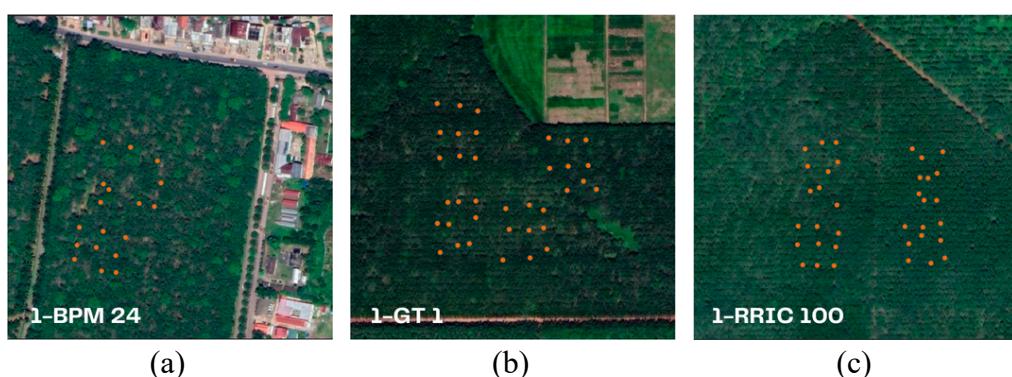
Citra multispektral *drone* diakuisisi pada dua periode berbeda, yaitu antara 18-19 Januari dan 15-16 Juni 2022. Pencitraan dilakukan pada tiga lokasi berbeda dan menggunakan klon yang berbeda. Jumlah total citra yang diperoleh berjumlah 1671 yang setiap citra memiliki dimensi 1600x1300 piksel. Format file yang digunakan adalah JPG dan berformat warna RGB. Informasi rinci tentang jumlah citra multispektral *drone* yang diambil dapat ditemukan di Tabel 3.

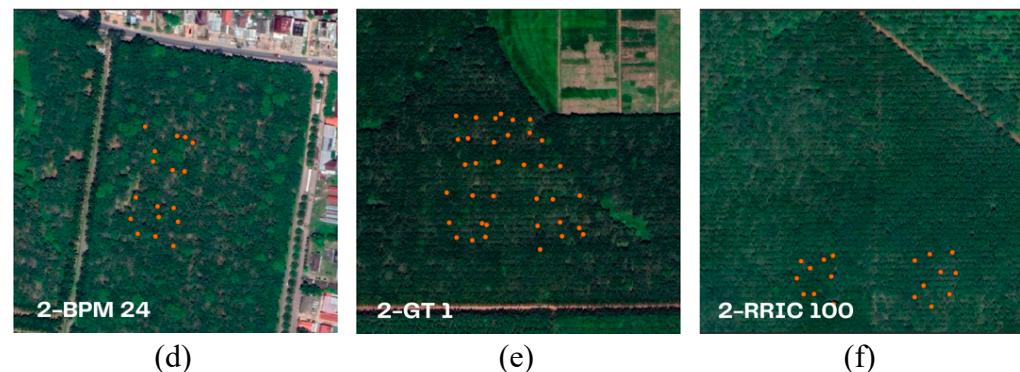
Tabel 3 Lokasi pengambilan data di Pusat Penelitian Karet Sembawa

Pengambilan	Area Survei (Klon)	Luas Area (Meter)	Usia Tanaman	Jumlah Penangkapan
Pengambilan 1	BPM 24	200 x 100	10 Tahun	290
	GT 1	200 x 200	11 Tahun	395
	RRIC 100	200 x 200	11 Tahun	354
Pengambilan 2	BPM 24	200 x 100	10 Tahun	276
	GT 1	200 x 200	11 Tahun	188
	RRIC 100	200 x 200	11 Tahun	168

### 4.1.2 Data *Ground Truth*

Data *ground truth* diperoleh pada tanggal yang sama dengan akuisisi citra multispektral *drone*. Pada pengambilan pertama, diperoleh 90 titik data *ground truth*, sedangkan pada pengambilan kedua, diperoleh 72 titik data *ground truth*. Data *ground truth* juga digunakan oleh pakar, Tri Rapani Febbiyanti, untuk menilai *severity level* tanaman karet berdasarkan pengamatan citra *hemispherical* pada setiap titik koordinatnya. Rincian lokasi titik koordinat yang dipilih ditampilkan pada Gambar 12.



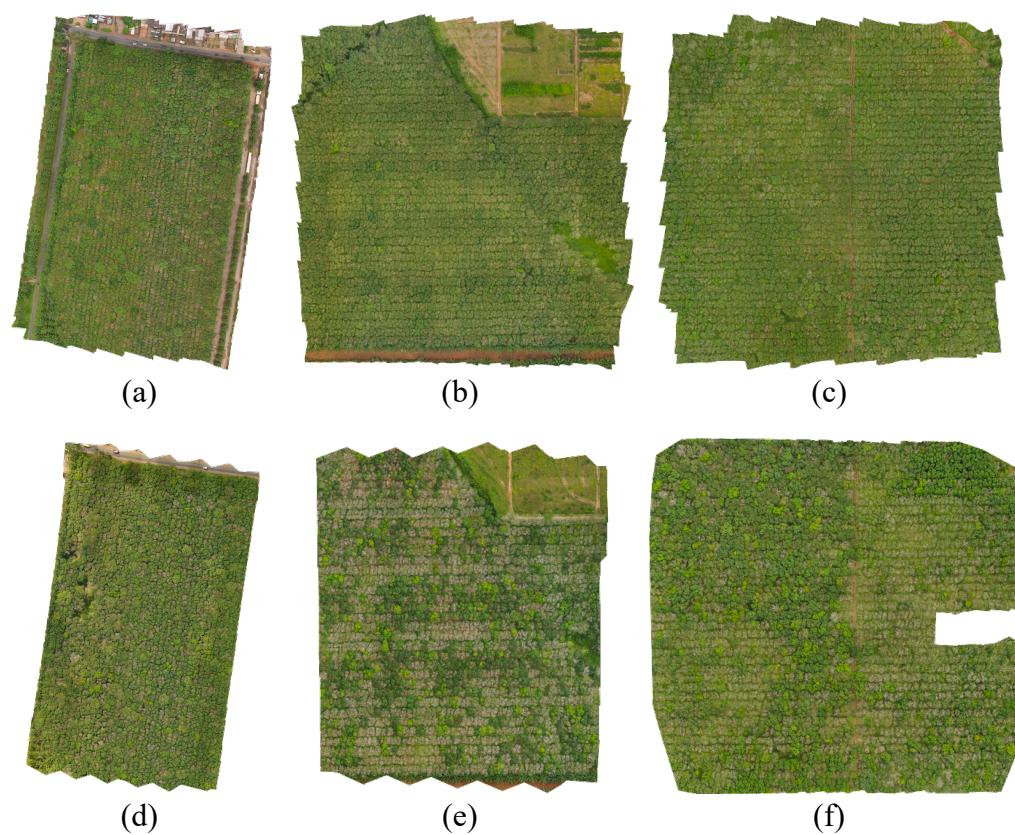


Gambar 12 Lokasi titik koordinat yang dipilih sebagai data *ground truth* pada lokasi Pengambilan 1 (a) BPM 24, (b) GT 1, dan (c) RRIC 100 dan Pengambilan 2 (d) BPM 24, (e) GT 1, dan (f) RRIC 100

## 4.2 Praproses Data

### 4.2.1 Pembuatan *Orthomosaic*

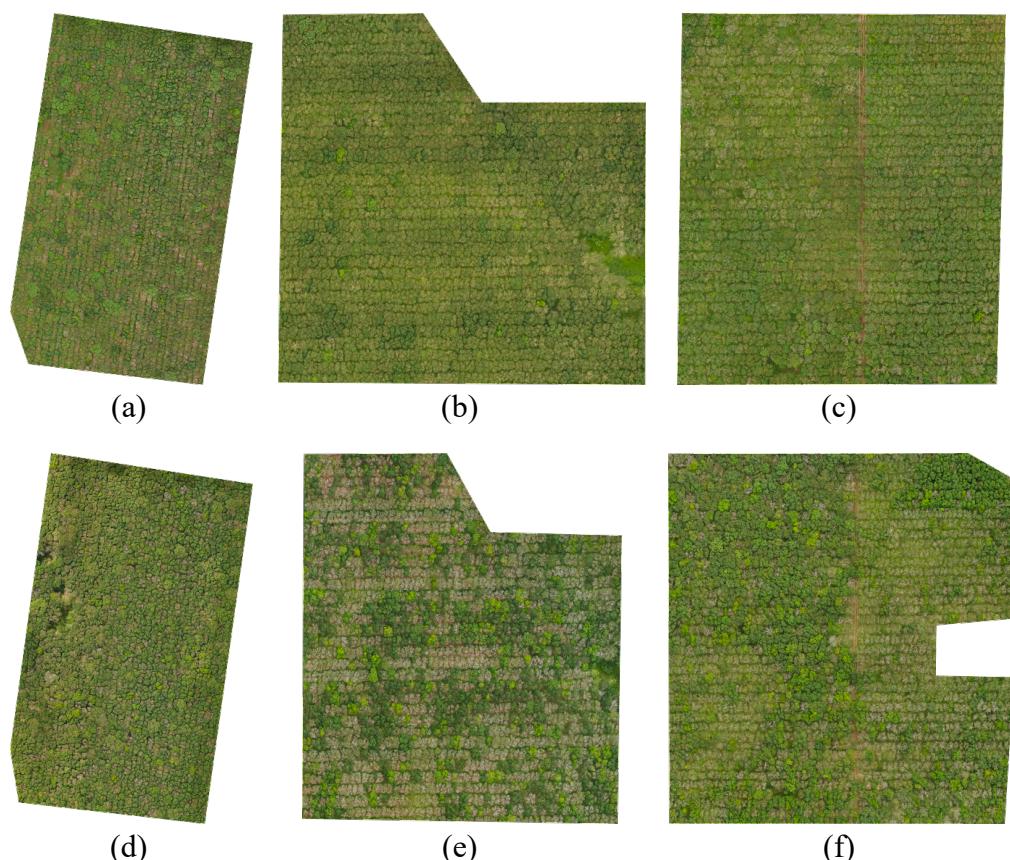
Proses pembuatan citra *orthomosaic* dilakukan menggunakan perangkat lunak Agisoft Metashape Pro. Proses ini melibatkan penggabungan citra-citra *drone* berformat warna RGB menjadi satu citra utuh yang disebut citra *orthomosaic*. Hasil dari proses ini menghasilkan enam citra *orthomosaic* dari masing-masing periode pengambilan dan jenis klon. Kemudian, setiap citra *orthomosaic* dieksport dalam format TIF dan diunggah ke asset GEE Code Editor untuk pemrosesan citra berikutnya. Gambar 13 menampilkan citra hasil *orthomosaic* yang telah dibuat.



Gambar 13 Citra orthomosaic pada lokasi pengambilan 1 (a) BPM 24, (b) GT 1, dan (c) RRIC 100 dan pengambilan 2 (d) BPM 24, (e) GT 1, dan (f) RRIC 100

#### 4.2.2 Clipping Orthomosaic

Pada platform Google Earth Engine (GEE), Proses *clipping* citra *orthomosaic* dilakukan dengan menggunakan fungsi ee.Image.clip berdasarkan *Region of Interest* (ROI). Penentuan ROI dilakukan dengan pembuatan poligon secara manual berdasarkan titik koordinat peta citra *orthomosaic*. Tujuan utama dari proses ini adalah untuk menghilangkan objek-objek selain perkebunan karet, seperti lahan kosong, pepohonan liar, jalan, dan bangunan. Dengan melakukan proses *clipping*, citra *orthomosaic* yang dihasilkan akan terfokus pada perkebunan karet secara spesifik sehingga meningkatkan relevansinya dalam mengidentifikasi gulma yang ada di dalam perkebunan karet. Gambar 14 menampilkan hasil *clipping* citra *orthomosaic*.



Gambar 14 Citra *clipping orthomosaic* pada lokasi pengambilan 1 (a) BPM 24, (b) GT 1, dan (c) RRIC 100 dan pengambilan 2 (d) BPM 24, (e) GT 1, dan (f) RRIC 100

#### 4.2.3 Segmentasi Data

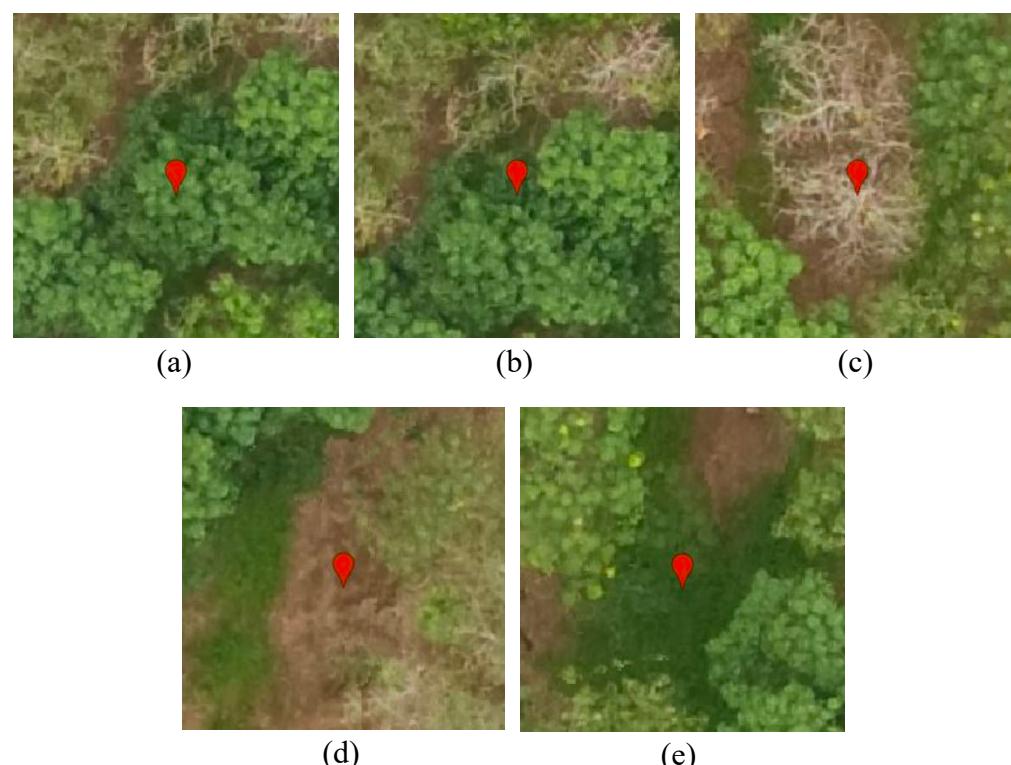
Proses segmentasi dilakukan untuk memisahkan objek gulma dan tanaman karet yang terdapat pada citra *orthomosaic*. Dalam implementasinya, citra *orthomosaic* berformat warna RGB akan diproses menggunakan fungsi ee.Clusterer.wekaKMeans pada platform Google Earth Engine (GEE). Tabel 4

menunjukkan parameter-parameter yang digunakan dalam proses *k-means++ clustering*.

Tabel 4 Parameter *k-means++ clustering* untuk segmentasi

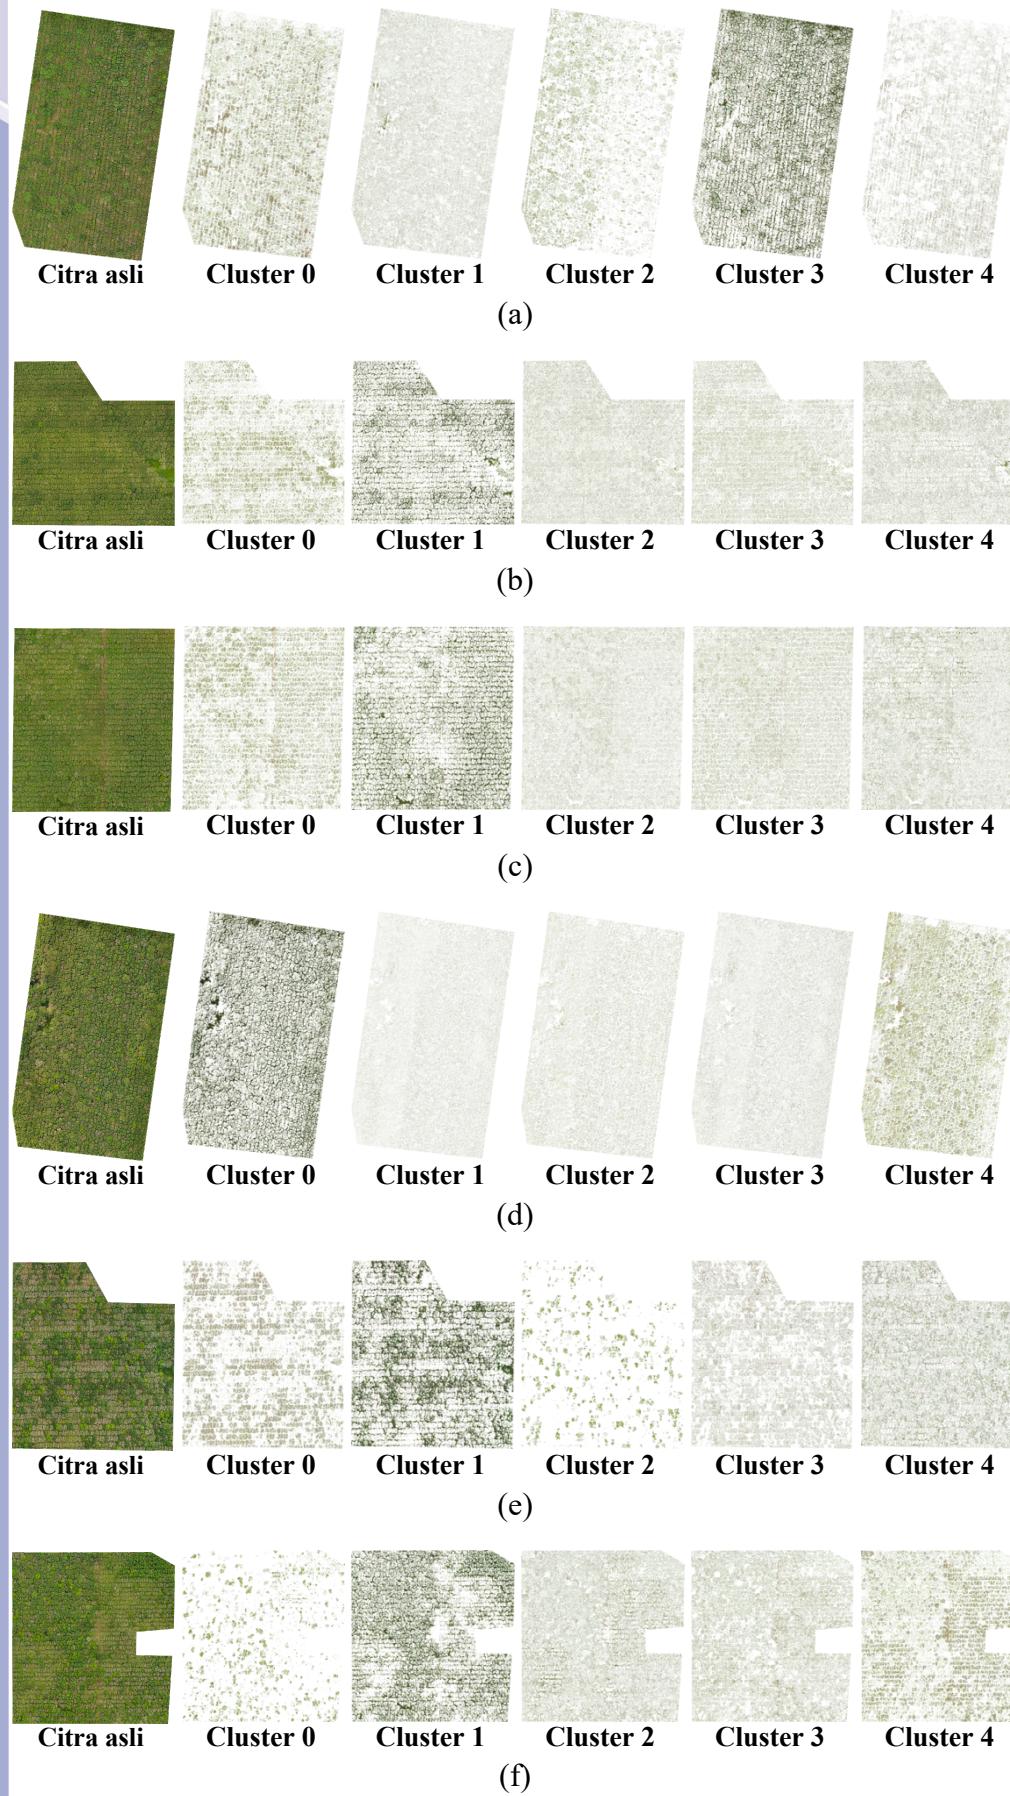
Parameter	Nilai
nClusters	5
init	1 ( <i>k-means++</i> )
distanceFunction	Euclidean

Dalam proses segmentasi, penting untuk memilih jumlah *cluster* yang sesuai agar objek utama dapat terpisah dengan tepat. Pemilihan lima *cluster* didasarkan pada keberadaan lima objek penting di perkebunan karet, meliputi kanopi atas, kanopi bawah, ranting, tanah, dan gulma. Gambar 15 memperlihatkan informasi lebih lanjut setiap objek yang dapat ditemukan pada citra perkebunan karet. Sedangkan, hasil segmentasi pada setiap *cluster* dapat dilihat pada gambar 16.



Gambar 15 Objek (a) tanaman karet bagian tajuk atas, (b) tajuk bawah, (c) ranting, (d) tanah, dan (e) gulma pada perkebunan karet

Hak Cipta Dilindungi Undang-undang  
1. Dilarang mengutip sebagian atau seluruh karya tulis ini tanpa mencantumkan dan menyebutkan sumber :  
a. Pengutipan hanya untuk kepentingan pendidikan, penelitian, penulisan karya ilmiah, penyusunan laporan, penulisan kritik atau tinjauan suatu masalah  
b. Pengutipan tidak merugikan kepentingan yang wajar IPB University.  
2. Dilarang mengumumkan dan memperbanyak sebagian atau seluruh karya tulis ini dalam bentuk apapun tanpa izin IPB University.





Hak Cipta Dilindungi Undang-undang  
1. Dilarang mengutip sebagian atau seluruh karya tulis ini tanpa mencantumkan dan menyebutkan sumber :

a. Pengutipan hanya untuk kepentingan pendidikan, penelitian, penulisan karya ilmiah, penyusunan laporan, penulisan kritik atau tinjauan suatu masalah

b. Pengutipan tidak merugikan kepentingan yang wajar IPB University.

2. Dilarang mengumumkan dan memperbanyak sebagian atau seluruh karya tulis ini dalam bentuk apapun tanpa izin IPB University.

Gambar 16 Citra segmentasi RGB pada setiap cluster pengambilan 1 (a) BPM 24, (b) GT 1, dan (c) RRIC 100 dan pengambilan 2 (d) BPM 24, (e) GT 1, dan (f) RRIC 100

Tahap selanjutnya setelah proses *clustering* adalah melakukan pengamatan visual pada setiap cluster untuk mengklasifikasikan objek-objek yang telah dihasilkan. Secara spesifik, objek-objek tersebut teridentifikasi sebagai tajuk atas, tajuk bawah, ranting, tanah, atau gulma. Hasil pengamatan untuk setiap *cluster* terdapat pada Tabel 5.

Tabel 5 Hasil pengamatan setiap *cluster* terhadap objek secara visual

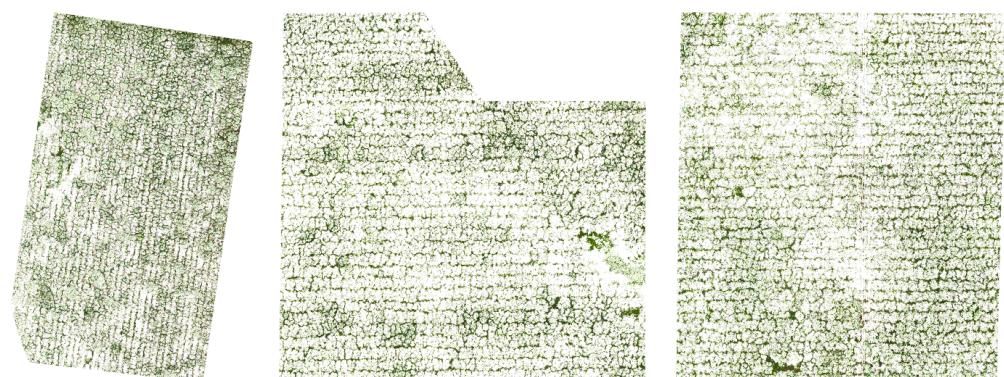
Citra	Cluster				
	0	1	2	3	4
1-BPM 24	Ranting, tanah	Tajuk bawah, gulma	Tajuk atas	Gulma	Tanah
1-GT 1	Ranting	Gulma	Tajuk atas	Tajuk atas	Tajuk bawah, gulma
1-RRIC 100	Ranting, tanah	Gulma	Tajuk atas	Tajuk atas	Tajuk bawah, gulma
2-BPM 24	Gulma	Tajuk atas	Tajuk bawah, gulma	Tajuk atas	Ranting, tanah
2-GT 1	Ranting	Gulma	Tajuk atas	Tajuk atas	Tajuk bawah, tanah
2-RRIC 100	Tajuk atas	Gulma	Tajuk bawah, gulma	Tajuk bawah, tanah	Ranting, tanah

Dari hasil pengamatan setiap *cluster*, diperlukan pendistribusian *cluster* dimana objek gulma dijadikan menjadi satu *cluster* gulma, sementara objek yang tidak termasuk gulma digabungkan akan menjadi *cluster* tanaman karet. Dengan demikian, objek-objek tanaman karet seperti kanopi atas, kanopi bawah, ranting, dan tanah akan digabungkan bersama dalam satu *cluster*. Tujuan utama pendistribusian *cluster* ini adalah untuk membedakan dan memisahkan antara objek gulma dan tanaman karet. Tabel 6 menampilkan rincian pendistribusian *cluster* kedalam *cluster* tanaman karet dan gulma. Gambar 17 mengilustrasikan hasil pendistribusian *cluster* pada citra RGB tanaman karet dan gulma.

Tabel 6 Penggabungan indeks *cluster* menjadi dua *cluster* yang disesuaikan

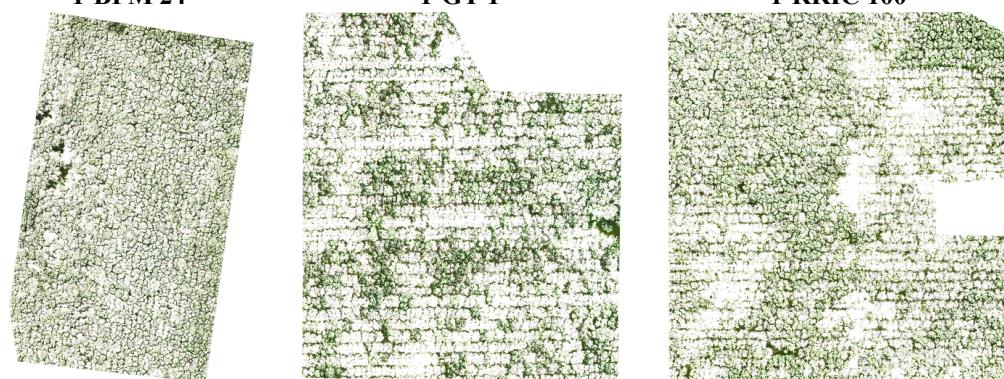
Citra	Cluster
-------	---------

	Tanaman Karet	Gulma
1-BPM 24	0, 1, 2, 4	3
1-GT 1	0, 2, 3, 4	1
1-RRIC 100	0, 2, 3, 4	1
2-BPM 24	1, 2, 3, 4	0
2-GT 1	0, 2, 3, 4	1
2-RRIC 100	0, 2, 3, 4	1



1-GT 1

1-RRIC 100



2-GT 1

2-RRIC 100

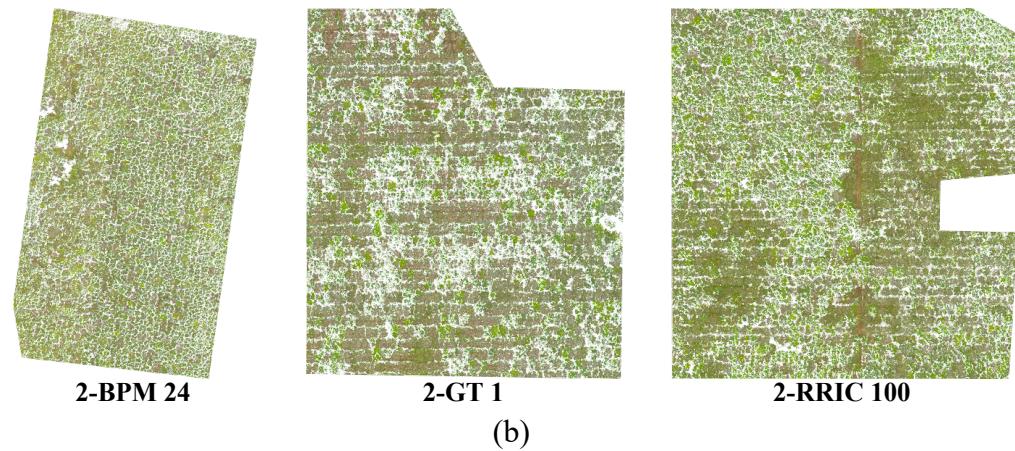
(a)



1-GT 1

1-RRIC 100

- Hak Cipta Dilindungi Undang-undang  
 1. Dilarang mengutip sebagian atau seluruh karya tulis ini tanpa mencantumkan dan menyebutkan sumber :  
 a. Pengutipan hanya untuk kepentingan pendidikan, penelitian, penulisan karya ilmiah, penyusunan laporan, penulisan kritik atau tinjauan suatu masalah  
 b. Pengutipan tidak merugikan kepentingan yang wajar IPB University.  
 2. Dilarang mengumumkan dan memperbanyak sebagian atau seluruh karya tulis ini dalam bentuk apapun tanpa izin IPB University.



Gambar 17 Hasil citra segmentasi RGB dari pendistribusian *cluster* menjadi dua *cluster* (a) gulma dan (b) tanaman karet (non-gulma)

Berdasarkan pendistribusian *cluster* yang telah disesuaikan, terdapat beberapa temuan visual yang perlu diperhatikan. Pada Gambar 17 (a), terlihat citra gulma masih mengandung objek tanah yang seharusnya objek tersebut terdapat pada citra tanaman karet. Meskipun demikian, pada Gambar 17 (b) terlihat bahwa citra segmentasi tanaman karet sudah cukup baik dalam merepresentasikan objek tanaman karet. Oleh karena itu, diperlukan peningkatan proses untuk meningkatkan hasil segmentasi guna mencapai hasil yang lebih optimal dan meminimalkan kesalahan segmentasi seperti yang terlihat pada citra segmentasi gulma.

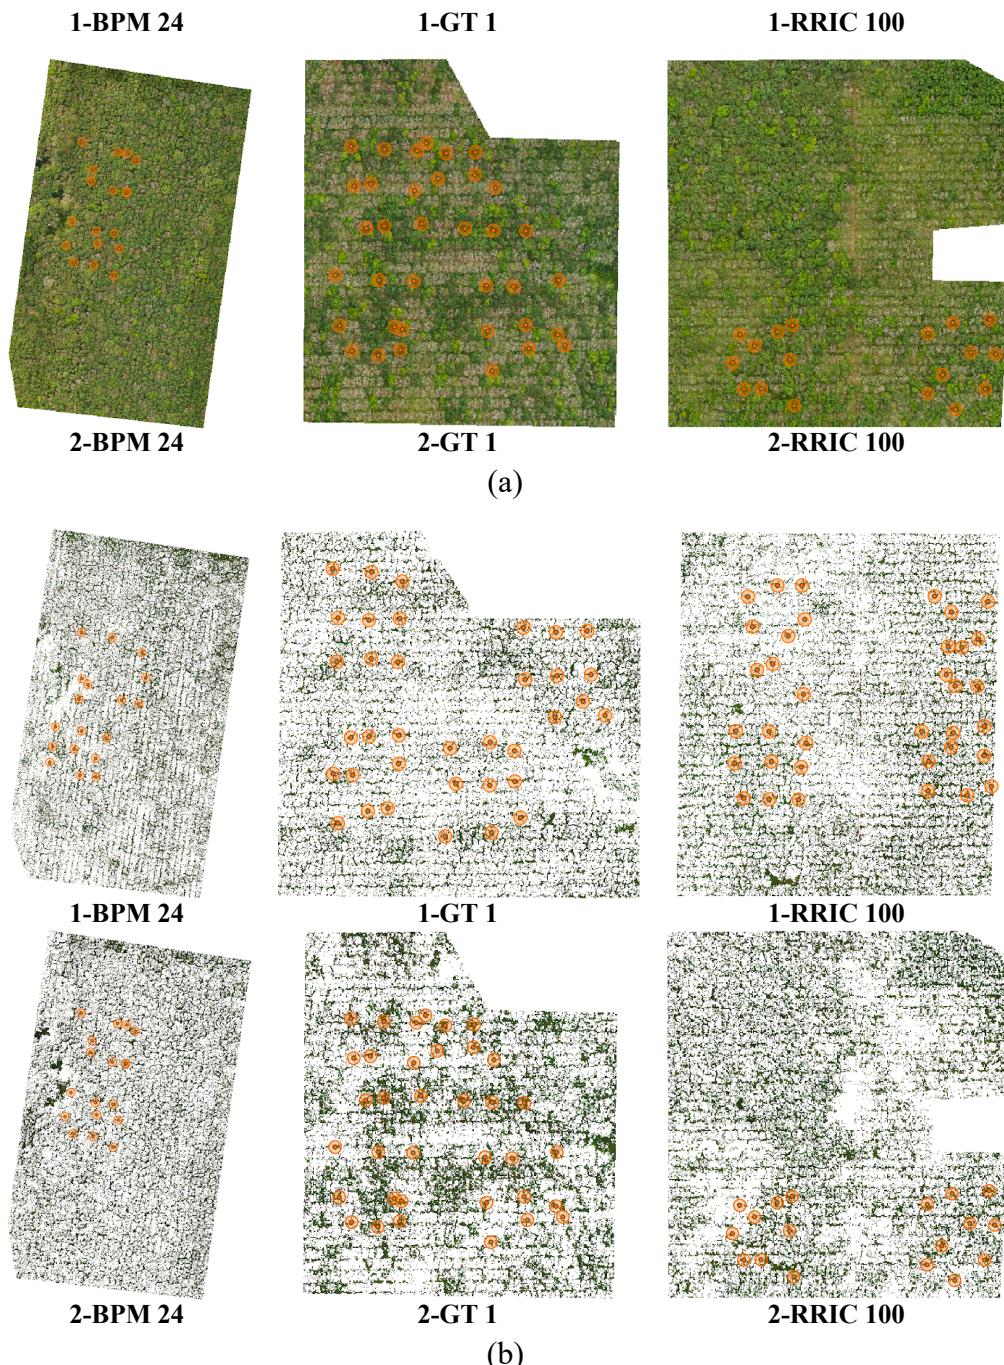
#### 4.2.4 Clipping Ground Truth dan Pelabelan

Proses *clipping ground truth* menggunakan aplikasi QGIS melibatkan dua jenis citra *orthomosaic*, yaitu citra *orthomosaic* asli dan citra *orthomosaic* gulma. Proses ini bertujuan untuk mengumpulkan data berdasarkan titik koordinat pada citra *orthomosaic* yang akan digunakan sebagai dataset. Radius *buffer* 4 meter diterapkan selama proses *clipping*. Terdapat 324 citra yang berhasil di-*clipping* mencakup 162 citra asli dan 162 citra gulma. Transformasi label akan dilakukan pada citra gulma. Dalam hal ini, setiap citra gulma akan diubah menjadi format warna biner (hitam dan putih) untuk dijadikan label dengan menggunakan fungsi dari *library OpenCV* pada platform Google Colab. Ilustrasi dari *clipping ground truth* dapat dilihat pada gambar 18.



Hak Cipta Dilindungi Undang-undang  
 1. Dilarang mengutip sebagian atau seluruh karya tulis ini tanpa mencantumkan dan menyebutkan sumber :  
 a. Pengutipan hanya untuk kepentingan pendidikan, penelitian, penulisan karya ilmiah, penyusunan laporan, penulisan kritik atau tinjauan suatu masalah.  
 b. Pengutipan tidak merugikan kepentingan yang wajar IPB University.

2. Dilarang mengumumkan dan memperbanyak sebagian atau seluruh karya tulis ini dalam bentuk apapun tanpa izin IPB University.

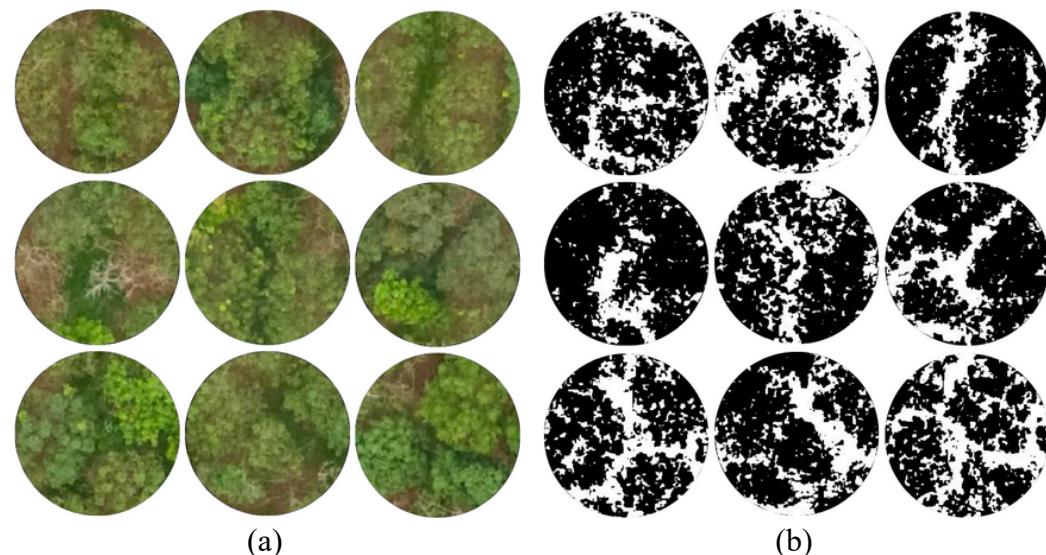


Gambar 18 Titik koordinat *ground truth* yang akan dilakukan clipping (a) citra perkebunan karet dan (b) citra gulma

### 4.3 Dataset

Dataset terdiri dari 162 citra asli dan 162 citra label. Citra asli merupakan citra perkebunan karet, sedangkan citra label merupakan citra hasil segmentasi gulma yang telah ditransformasi warnanya menjadi citra biner (hitam dan putih). Sebanyak 55,56% dari data citra merupakan hasil dari pengambilan pertama, sementara 44,44% merupakan hasil dari pengambilan kedua. Setiap citra memiliki dimensi 200 x 200 piksel. Dataset ini akan digunakan sebagai *input* dari proses

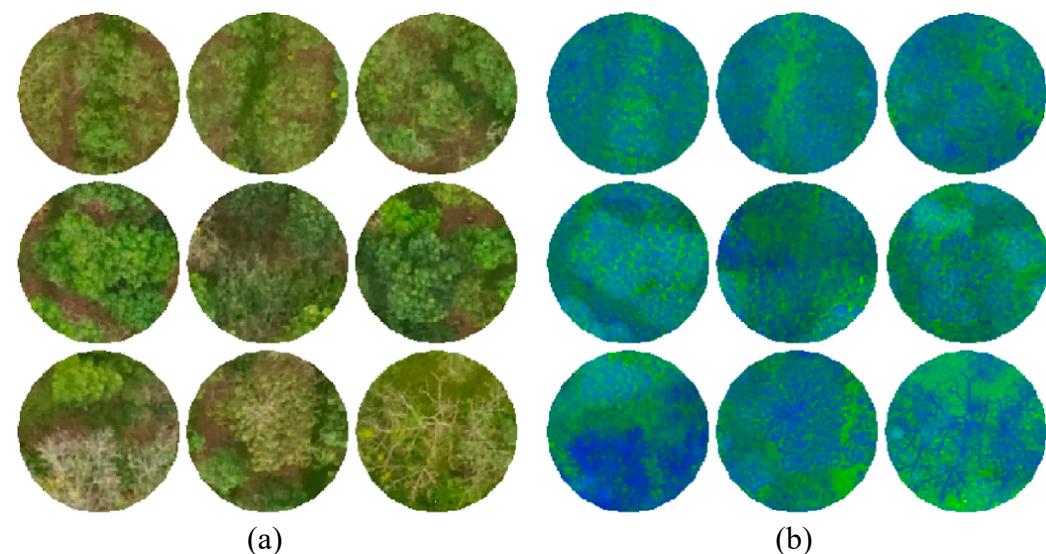
pelatihan dan pengujian model segmentasi semantik. Gambar 19 merupakan sampel citra asli dan citra label dari dataset.



Gambar 19 data citra (a) perkebunan karet dan (b) label gulma

#### 4.4 Transformasi Warna

Pada tahap transformasi warna, citra RGB akan dikonversi ke format warna HSV dengan menggunakan fungsi dari *library* OpenCV pada Google Colab. Ruang warna HSV (*Hue*, *Saturation*, *Value*) memudahkan identifikasi objek gulma karena dapat memisahkan informasi warna, kecerahan, dan intensitas kecerahan ke dalam komponen-komponen yang terpisah. Dalam ruang warna HSV, komponen *Hue* menggambarkan informasi warna, komponen *Saturation* menggambarkan kecerahan warna, dan komponen *Value* menggambarkan intensitas kecerahan. Dengan memanfaatkan ruang warna HSV, diharapkan identifikasi objek gulma dapat dilakukan dengan lebih efektif. Gambar 20 mengilustrasikan format warna sebelum dilakukan transformasi warna yaitu RGB dan sesudah dilakukan transformasi warna yaitu HSV.



Gambar 20 Format warna (a) RGB dan (b) HSV

## 4.5 Segmentasi Semantik (*Deep Learning*)

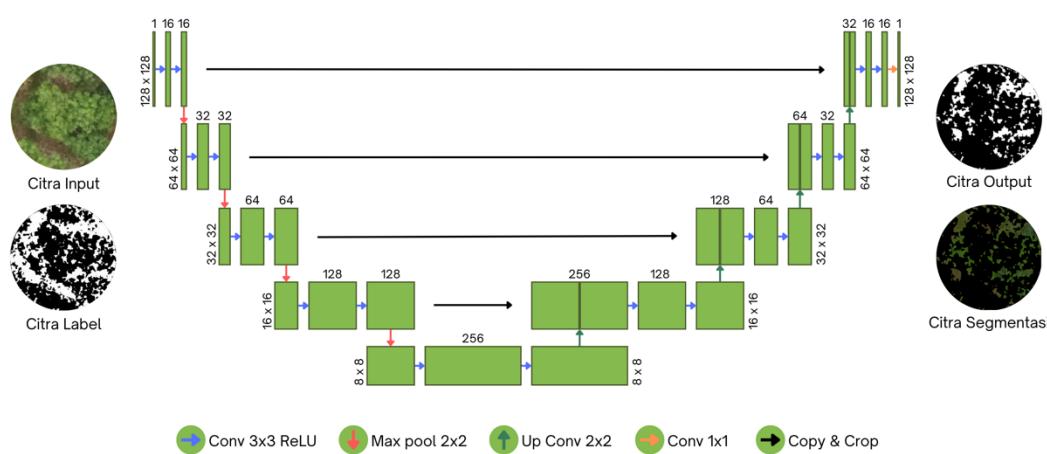
### 4.5.1 Data Latih dan Data Uji

Pembagian data dilakukan secara acak untuk memastikan bahwa data latih dan data uji yang digunakan dalam proses pelatihan dan pengujian memiliki representasi yang merata. Dengan demikian, model yang dibangun dapat belajar dari beragam pola dan karakteristik yang terdapat dalam dataset secara adil. Penggunaan metode acak juga membantu mengurangi bias yang mungkin timbul akibat pengambilan data yang tidak representatif.

Data latih sebanyak 70% dari dataset digunakan untuk melatih model agar dapat mempelajari pola dan hubungan yang ada dalam data. Sementara itu, data uji sebanyak 30% dari dataset digunakan untuk menguji performa model yang telah dilatih, sehingga dapat memperoleh estimasi sejauh mana model mampu melakukan prediksi yang akurat. Selain itu, untuk memastikan kesesuaian dengan model *input* pada proses *deep learning*, kedua jenis data tersebut akan diubah ukurannya menjadi 128x128 piksel. Hal ini dilakukan agar data latih dan data uji sesuai dengan format *input* yang dibutuhkan oleh model dalam proses *deep learning*.

### 4.5.2 Pelatihan Model

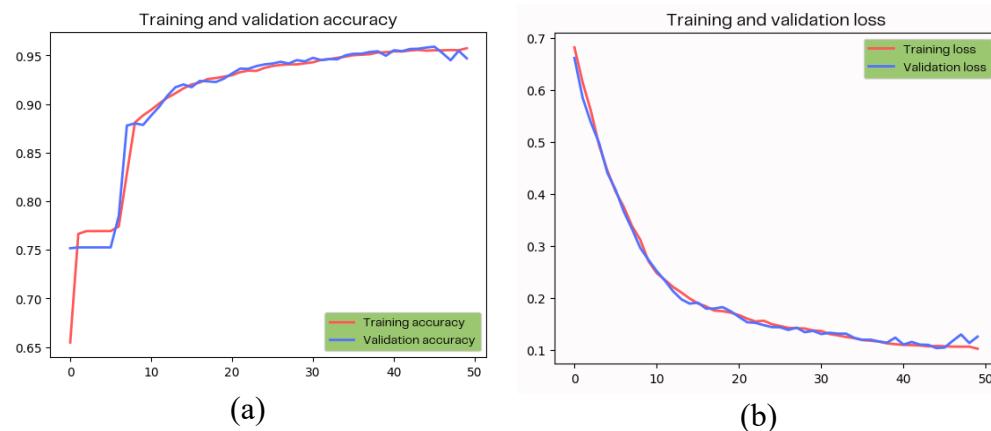
Model dilatih menggunakan metode segmentasi semantik berbasis *deep learning* dengan arsitektur U-Net seperti yang diilustrasikan pada Gambar 21. Arsitektur U-Net yang diterapkan dalam penelitian ini merupakan hasil pengembangan berdasarkan kajian literatur yang relevan dan telah disesuaikan dengan kebutuhan dan karakteristik dataset yang digunakan. Proses pelatihan melibatkan 200 iterasi di mana data dibagi menjadi data latih dan data validasi menggunakan parameter *validation\_split*=0.1.



Gambar 21 Model U-Net

Proses pelatihan model terhenti pada iterasi ke-50 karena penerapan pendekaran *early stopping*. Pendekatan *early stopping* digunakan untuk menghentikan proses pelatihan jika terjadi penurunan signifikan dalam nilai *val\_loss* selama 5 iterasi berturut-turut. Tindakan ini dilakukan untuk mencegah

terjadinya *overfitting* dan mencapai model yang optimal. Gambar 22 merupakan grafik akurasi dan *loss* dari pelatihan model.

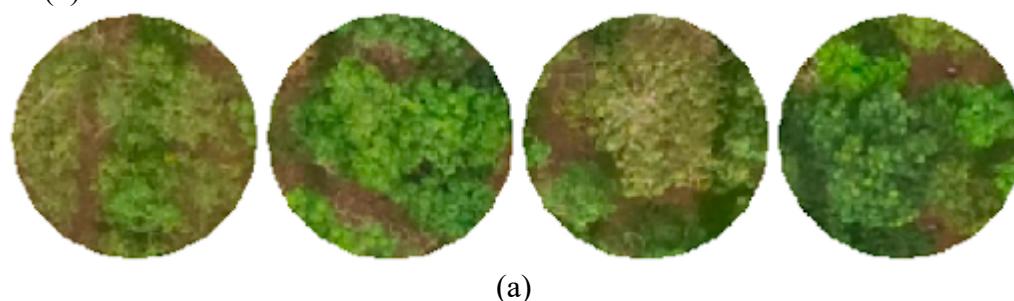


Gambar 22 Grafik (a) akurasi pelatihan dan validasi dan (b) loss pelatihan dan validasi

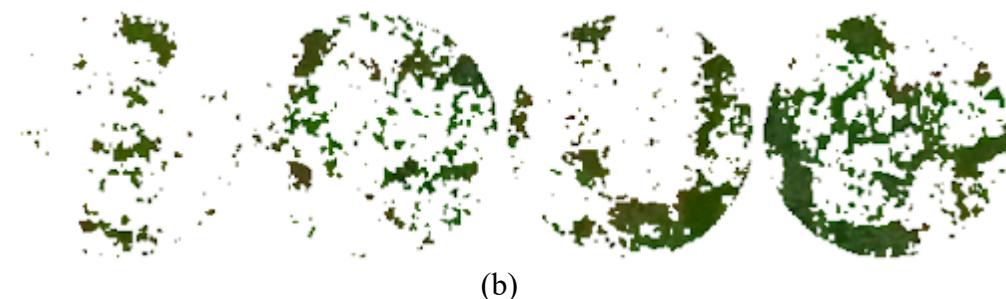
Pelatihan model menghasilkan akurasi pelatihan sebesar 95,74% dan akurasi validasi sebesar 94,69%. Selain itu, tingkat kerugian pelatihan sebesar 10,29% dan kerugian validasi sebesar 12,61%. Hasil ini menunjukkan bahwa model memiliki kemampuan yang baik dalam melakukan prediksi dengan tingkat akurasi yang tinggi dan tingkat kerugian yang rendah. Dengan demikian, hasil pelatihan ini memberikan indikasi bahwa model tersebut memiliki kinerja yang baik dan andal.

#### 4.5.3 Pengujian Model

Pada tahap pengujian, model yang telah dilatih akan diuji menggunakan data uji. Tujuan utama dari pengujian ini adalah untuk memvalidasi kinerja dan kemampuan prediksi model dalam mengidentifikasi keberadaan gulma pada citra asli. Dalam proses pengujian, model akan memprediksi keberadaan gulma pada setiap citra. Data uji atau citra *input* dapat dilihat pada Gambar 23 (a), sedangkan hasil identifikasi gulma atau citra *output* dapat dilihat pada Gambar 23 (b).



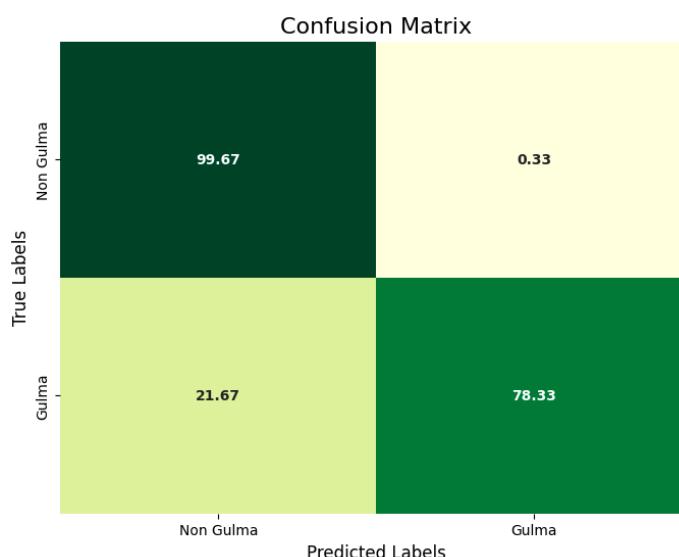
(a)



Gambar 23 Citra pengujian model (a) citra asli dan (b) citra segmentasi gulma

#### 4.5.4 Evaluasi Model

Hasil dari *confusion matrix*, pada Gambar 24, menunjukkan bahwa kemampuan model dalam mengidentifikasi kelas "non-gulma" sangat baik dengan akurasi mencapai 99,67% dan tingkat kesalahannya hanya sebesar 0,33%. Namun, dalam hal mengidentifikasi kelas "gulma", Model hanya mampu mencapai akurasi sebesar 78,33%. Dengan demikian terdapat kesalahan sebesar 21,67% dalam proses pengidentifikasiannya.



Gambar 24 *Confusion matrix* antara gulma dan non gulma

Dari hasil *confusion matrix* dapat dievaluasi kinerja model lebih terperinci seperti *accuracy*, *precision*, *recall*, dan *F1-score*. Pada tabel 7 diketahui bahwa model berhasil mencapai tingkat *accuracy* pengujian sebesar 0.95. Sementara itu, *precision* untuk kelas "non-gulma" mencapai 0.94 dan kelas "gulma" mencapai 0.99. Hasil ini menunjukkan bahwa model memiliki tingkat ketepatan yang tinggi dalam mengidentifikasi kelas "non-gulma" dan "gulma".

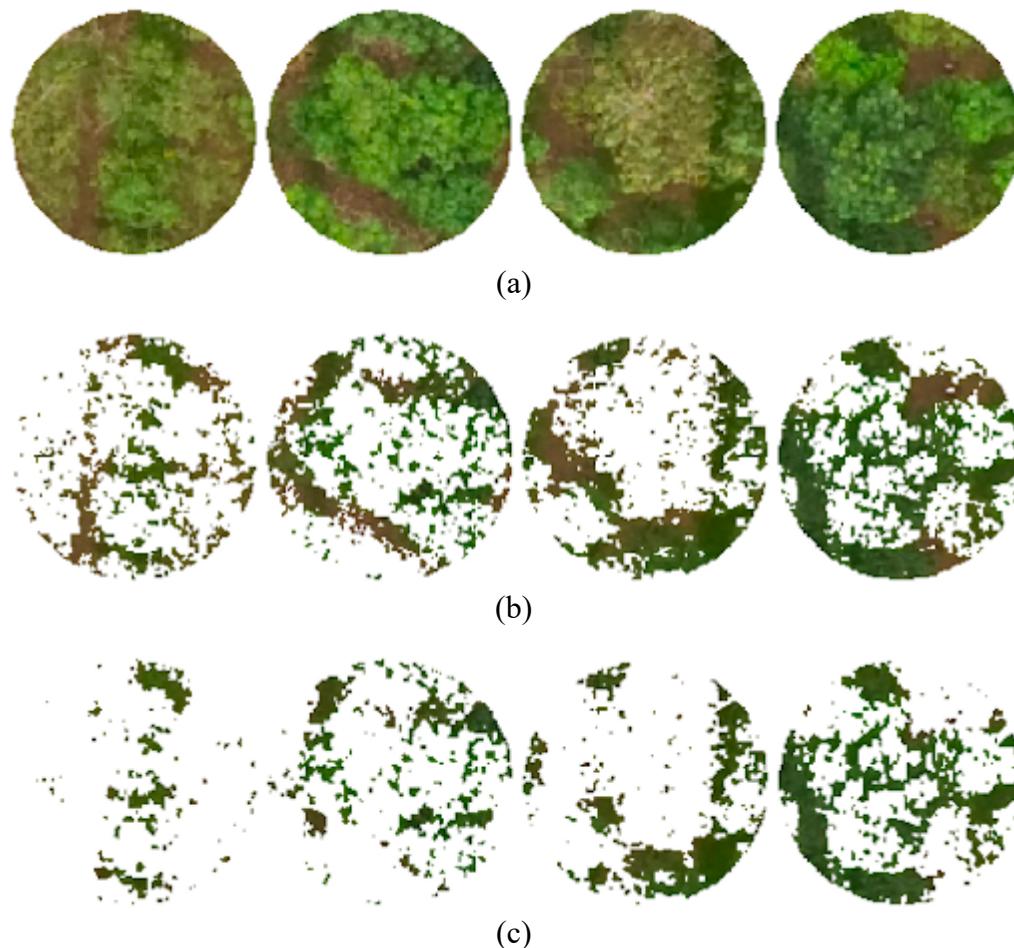
Tabel 7 Metrik evaluasi identifikasi gulma pada citra perkebunan karet

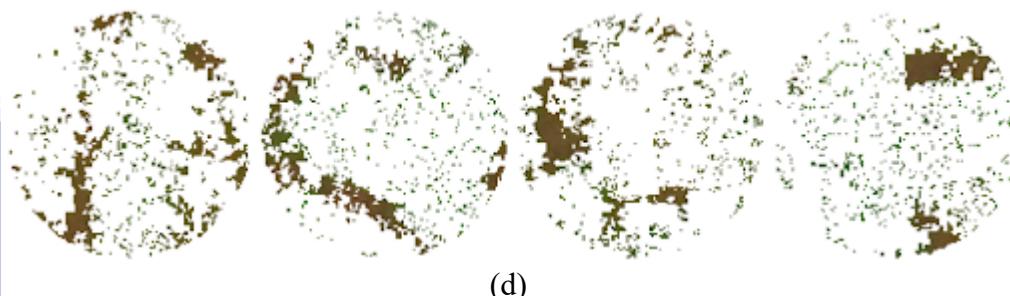
	Precision	Recall	F1-Score	Support
<b>Non Gulma</b>	0.94	1.00	0.97	614250



<b>Gulma</b>	0.99	0.78	0.87	188566
<b>Accuracy</b>			0.95	802816

Sementara itu, *recall* kelas "non-gulma" diperoleh sebesar 1.00 yang menandakan model mampu mengidentifikasi kelas "non-gulma" dengan sempurna. Namun, *recall* untuk kelas "gulma" hanya sebesar 0.78, hal ini mengindikasikan adanya kesalahan identifikasi pada kelas "gulma". Selain itu, *F1-score* "non-gulma" diperoleh sebesar 0.97 yang menunjukkan tingkat keseimbangan yang baik antara antara *precision* dan *recall* dalam mengenali kelas "non-gulma". Nilai *F1-score* untuk kelas "gulma" adalah 0.87 yang mengindikasikan tingkat keseimbangan yang sedikit lebih rendah dibandingkan dengan kelas "non-gulma". Hasil ini menunjukkan bahwa model memiliki performa yang baik dalam mengidentifikasi kelas "non-gulma", tetapi terdapat ketidaksesuaian dalam mengidentifikasi kelas "gulma".





(d)

Gambar 25 Evaluasi hasil segmentasi gulma pada citra perkebunan karet (a) citra asli, (b) citra segmentasi *k-means++ clustering* atau label gulma, (c) citra segmenetasi *k-means++ clustering + semantik berbasis deep learning* atau prediksi gulma, dan (d) perpotongan antara Gambar 25(b) dan Gambar 25(c)

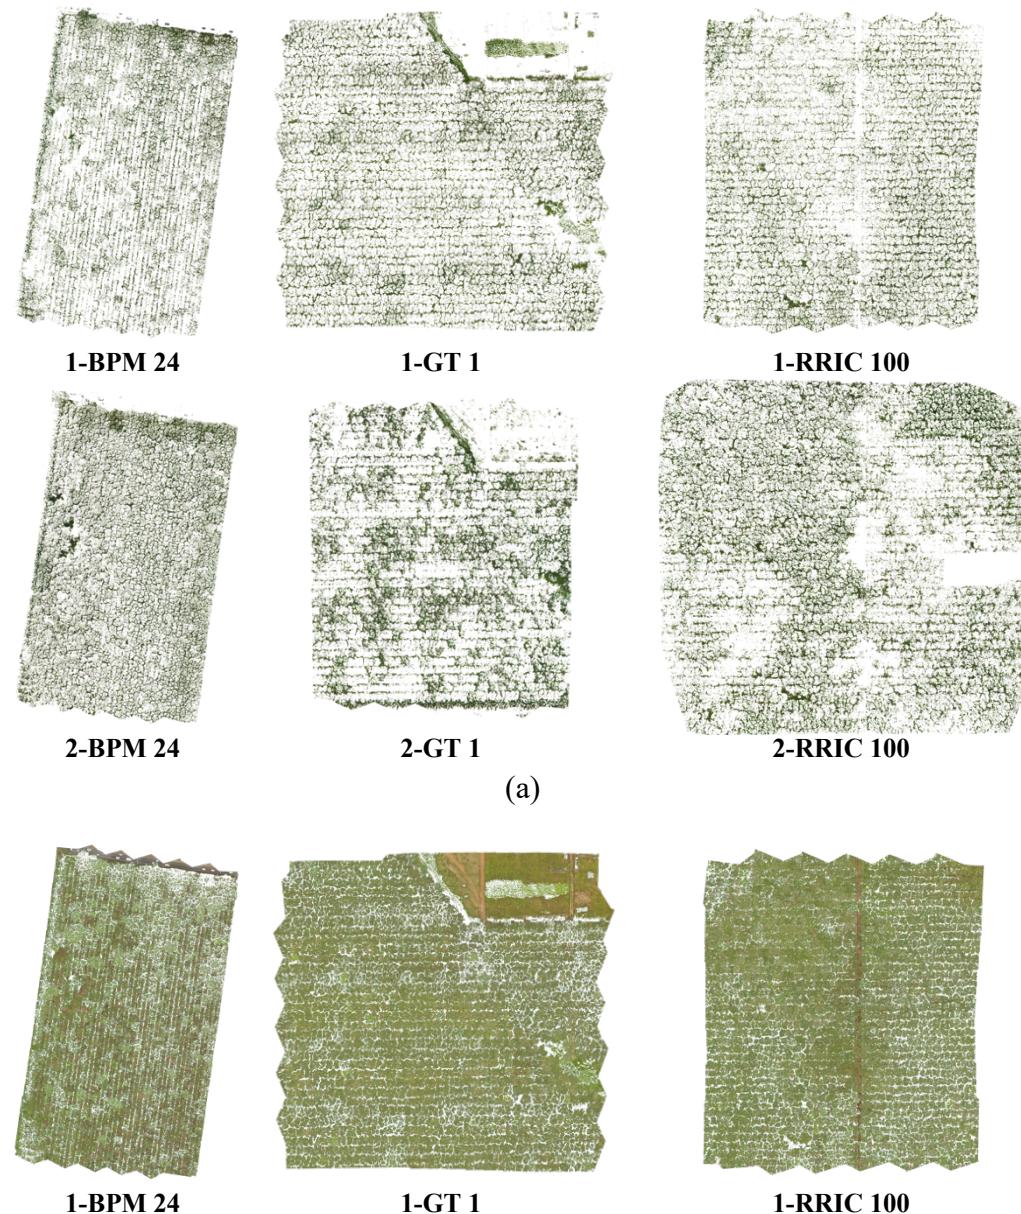
Untuk mengevaluasi hasil segmentasi model segmentasi semantik berbasis *deep learning*, diperlukan perbandingan hasil dari proses segmentasi sebelumnya yang hanya menggunakan metode *k-means++ clustering*. Perbandingan tersebut akan memberikan informasi tentang sejauh mana model mampu mengidentifikasi gulma dengan baik. Citra pada Gambar 25(a) merupakan citra asli perkebunan karet yang dijadikan sebagai data uji. Sementara itu, Gambar 25(b) menunjukkan hasil segmentasi citra gulma menggunakan metode *k-means++ clustering* yang mana masih terdapat objek “tanah” yang terlihat pada citra hasil segmentasinya.

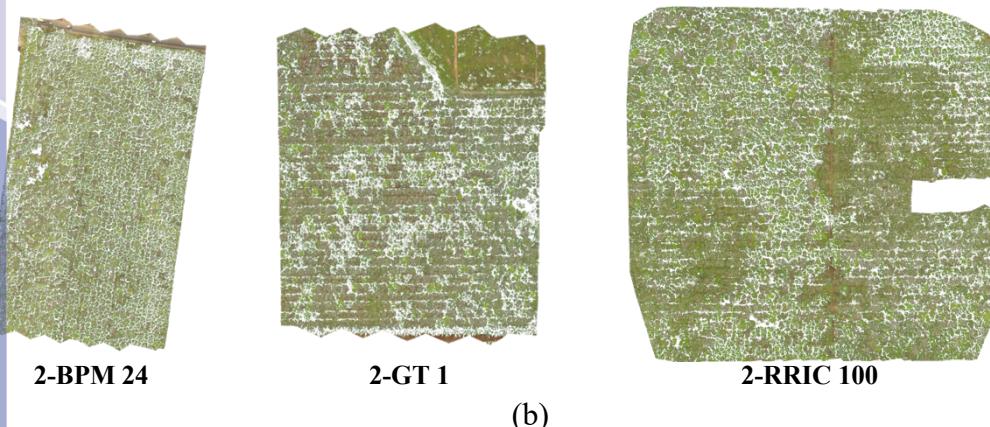
Pada Gambar 25(c), hasil prediksi gulma dari metode segmentasi semantik berbasis *deep learning* berhasil meningkatkan identifikasi gulma dengan cukup baik dengan tidak menyertakan tanah ke dalam hasil segmentasinya. Perbedaan tersebut dapat dilihat pada Gambar 25(d) yang merupakan perpotongan antara hasil segmentasi sebelum dan sesudah dilakukan proses lanjutan menggunakan metode segmentasi semantik berbasis *deep learning*. Gambar tersebut memperlihatkan bahwa sebagian besar objek “tanah” yang teridentifikasi sebagai objek “gulma” pada metode *k-means++ clustering* berhasil diperbaiki dengan menggunakan metode segmentasi semantik berbasis *deep learning*. Perbandingan hasil segmentasi tersebut memperjelas bahwa metode segmentasi semantik berbasis *deep learning* mampu meningkatkan hasil identifikasi gulma yang lebih baik dibandingkan hanya dengan metode segmentasi menggunakan *k-means++ clustering* saja.

Berdasarkan hasil evaluasi model, dapat dinyatakan bahwa kesalahan pengidentifikasi kelas “gulma” sebesar 21,67% tersebut merupakan suatu perbaikan hasil pengidentifikasi dari metode sebelumnya yang hanya menggunakan metode *k-means++ clustering* saja. Hasil ini sesuai dengan perbandingan citra hasil segmentasi menggunakan metode *k-means++ clustering* dan citra hasil segmentasi menggunakan metode segmentasi semantik berbasis *deep learning*. Pada hasil segmentasi menggunakan *k-means++ clustering*, terdapat kesalahan di mana tanah yang seharusnya bagian dari kelas “non-gulma” teridentifikasi sebagai kelas “gulma”. Namun, kesalahan tersebut dapat diperbaiki dengan menggunakan metode segmentasi semantik berbasis *deep learning* yang mampu mengenali kelas “gulma” tanpa menyertakan tanah ke dalam hasil segmentasi.

## 4.6 Implementasi Model

Pada tahap implementasi, model berhasil memprediksi gulma pada enam citra orthomosaic. Hasil segmentasi yang diperoleh, terutama segmentasi “kebun karet” atau “non-gulma”, akan digunakan untuk mengidentifikasi tingkat Kesehatan tanaman karet. Hasil segmentasi citra dapat dilihat pada Gambar 26.





Gambar 26 Hasil segmentasi dari model yang berhasil diimplementasikan (a) segmentasi gulma dan (b) segmentasi tanaman karet

Hak Cipta Dilindungi Undang-undang  
1. Dilarang mengutip sebagian atau seluruh karya tulis ini tanpa mencantumkan dan menyebutkan sumber :  
a. Pengutipan hanya untuk kepentingan pendidikan, penelitian, penulisan karya ilmiah, penyusunan laporan, penulisan kritik atau tinjauan suatu masalah  
b. Pengutipan tidak merugikan kepentingan yang wajar IPB University.  
2. Dilarang mengumumkan dan memperbanyak sebagian atau seluruh karya tulis ini dalam bentuk apapun tanpa izin IPB University.

## V SIMPULAN DAN SARAN

### 5.1 Simpulan

Pada citra hasil segmentasi menggunakan *k-means++ clustering*, terdapat kesalahan dalam pengidentifikasi kelas "gulma" di mana sebagian tanah yang seharusnya bagian dari kelas "non-gulma" teridentifikasi sebagai kelas "gulma". Namun, kesalahan tersebut dapat diperbaiki dengan menggunakan metode segmentasi semantik berbasis *deep learning* yang mampu mengenali kelas "gulma" tanpa menyertakan tanah ke dalam hasil segmentasi. Tingkat kesalahan dalam mengidentifikasi kelas "gulma" mencapai 21,67%, yang dapat disebabkan oleh kemungkinan kesalahan dalam mengenali objek tanah yang sebelumnya dianggap sebagai kelas "gulma" pada hasil segmentasi menggunakan metode *k-means++ clustering*.

Selain itu, metode segmentasi semantik berbasis *deep learning* berhasil mencapai tingkat akurasi sebesar 95% dalam mengidentifikasi antara kelas "gulma" dan "non-gulma". Hasil ini menunjukkan tingkat ketepatan yang tinggi dalam mengidentifikasi kelas "non-gulma" dengan akurasi mencapai 99,67% dan kelas "gulma" dengan akurasi mencapai 78,33%. Berdasarkan hasil tersebut, dapat disimpulkan bahwa metode *k-means++ clustering* memiliki performa yang baik dalam mengidentifikasi kelas "non-gulma", namun kurang efektif dalam mengidentifikasi kelas "gulma". Oleh karena itu, alternatif yang dapat diterapkan untuk meningkatkan akurasi dalam mengidentifikasi kelas "gulma" adalah dengan menggunakan metode segmentasi semantik berbasis *deep learning*.

### 5.2 Saran

Model ini diharapkan dapat diintegrasikan pada perangkat keras yang mampu melakukan tugas *remote sensing* seperti *drone*. Integrasi model pada perangkat keras *drone* akan memberikan akses yang lebih mudah dan akurat bagi para petani dalam mendeteksi gulma serta memantau kondisi tanaman karet secara *real-time*. Dengan keunggulan tersebut, para petani dapat mengambil tindakan preventif atau korektif dengan cepat, meningkatkan efisiensi pertanian, dan mengoptimalkan hasil panen tanaman karet.





## DAFTAR PUSTAKA

- [ANRPC] Association of Natural Rubber Producing Countries. 2021. National Rubber Trends Statistics 2020. *ANRPC*. 12(6): 1-12.
- Arthur D, Vassilvitskii S. 2007. K-means++: The advantages of careful seeding. *SODA '07: Proceedings of the Eighteenth Annual ACM-SIAM Symposium on Discrete Algorithms*. hlm 1027–1035. Tersedia pada: <https://dl.acm.org/doi/10.5555/1283383.1283494>.
- Aubaidan B, Mohd M, Albared M. 2014. Comparative study of k-means and k-means++ clustering algorithms on crime domain. *Journal of Computer Science*. 10(7):1197–1206. doi:10.3844/jcssp.2014.1197.1206.
- Azizan FA, Kiloes AM, Astuti IS, Aziz AA. 2021. Application of optical remote sensing in rubber plantations: A systematic review. *Remote Sensing*. 13(3):429. doi: 10.3390/rs13030429.
- Barbaś P, Sawicka B, Marczak BK, Pszczołkowski P. 2020. Effect of Mechanical and Herbicide Treatments on Weed Densities and Biomass in Two Potato Cultivars. *Agriculture*. 10(455): 18. doi: 10.3390/rolnictwo10100455.
- [BPS] Badan Pusat Statistik. 2020. Statistik Karet Indonesia 2020. Jakarta: Badan Pusat Statistik. Tersedia pada: <https://www.bps.go.id/publication/2021/11/30/bc85ddce5e674dc744b69abb/statistik-karet-indonesia-2020.html>.
- Bua PML. 2022. Analisis indeks vegetasi menggunakan citra multispektral pada drone untuk pengukuran kesehatan tanaman karet (studi kasus: pusat penelitian karet sembawa) [skripsi]. Bogor: Institut Pertanian Bogor.
- Chen G, Thill JC, AAnantsuksomsri S, Tontisirin N, Tao R. 2018. Stand age estimation of rubber (*Hevea brasiliensis*) plantations using an integrated pixel- and object-based tree growth model and annual Landsat time series. *ISPRS Journal of Photogrammetry and Remote Sensing*. 144: 94-104. doi: 10.1016/j.isprsjprs.2018.07.003.
- Chicco D, Jurman G. 2020. The advantages of the matthews correlation coefficient (mcc) over f1 score and accuracy in binary classification evaluation. *BMC Genomics*. 21(6): 1-13. doi: 10.1186/s12864-019-6413-7.
- [Dekarindo] Dewan Karet Indoensia. 2021. *Data industri karet indonesia*. Jakarta: Dewan Karet Indonesia.
- [FAO] Food and Agricultural Organization. 2020. *FAOSTAT*. [Diakses 2022 Nov 29]. <http://www.fao.org/faostat/en/?#data/QC>.
- [FAO] Food and Agricultural Organization. 2021. *FAOSTAT*. [Diakses 2022 Nov 29]. <http://www.fao.org/faostat/en/?#data/QC>.
- Febbiyanti TR, Fairuzah Z. 2019. Identifikasi penyebab kejadian luar biasa penyakit gugur daun karet di Indonesia. *Jurnal Penelitian Karet*. 37(2): 193-206. doi:10.22302/ppk.jpk.v37i2.616.
- [GA] Grow Asia. 2020. Case study: Rubber in Indonesia. [Diakses 2022 Nov 29]. [http://exchange.growasia.org/system/files/200615\\_GA%20Rubber%20Report\\_Digital%20%28Final%29.pdf](http://exchange.growasia.org/system/files/200615_GA%20Rubber%20Report_Digital%20%28Final%29.pdf).
- Hadinata PN, Simanta D, Liyanto E. 2021. Deep convolutional neural network untuk mendeteksi retak pada permukaan beton yang memiliki void. *Journal of Sustainable Construction*. 1(1): 45-55. doi: 10.26593/josc.v1i1.5151.

- Hartawan R. 2012. Kompatibilitas batang bawah karet klon GT 1 dengan mata entres beberapa karet klon generasi V. *Agroscientiae*. 19:137–142.
- Hasan M, Ahmad-Hamdani MS, Rosli AM, Hamdan H. 2021. Bioherbicides: An Eco-Friendly Tool for Sustainable Weed Management. *Plants*, 10(6): 1212. doi: 10.3390/plants10061212.
- Maryani Y, Astuti Y. 2019. *Buku Saku Penyakit Gugur Daun Karet (GDK) Pestalotiopsis sp.* Jakarta: Direktorat Perlindungan Perkebunan - Kementerian Pertanian 2019.
- Mahé I, Cordeau S, Bohan DA, Derrouch D, Dessaint F, Millot D, Chauvel B. 2020. Soil seedbank: old methods for new challenges in agroecology?. *Annals of Applied Biology*. 178(1): 23–38. doi: 10.1111/aab.12619.
- [NM] Nation Master. 2020. Top countries in natural rubber net production. [Diakses 2022 Nov 29]. <https://www.nationmaster.com/nmx/ranking/natural-rubber-net-production>.
- Nugroho AD, Prasada IM, Lakner Z. 2022. Performance and forecast of Indonesian rubber exports to the central european countries. *OISAA Journal of Indonesia Emas*. 5(1): 66-81. doi: 10.52162/jie.2022.005.01.8.
- Payne AR. 1962. The dynamic properties of carbon black-loaded natural rubber vulcanizates. Part I. *Journal of Applied Polymer Science*. 6(19): 57-63. doi: 10.1002/app/1962.070061906.
- Ronneberger O, Fischer P, Brox T. 2015. U-net: convolutional networks for biomedical image segmentation. *Medical Image Computing and Computer-Assisted Intervention-MICCAI 2015*. 9351: 234-241. doi: 10.1007/978-3-319-24574-4\_28
- Sokolova M, Japkowicz N, Szpakowicz S. 2006. Beyond accuracy, f-score, and roc: a family of discriminant measures for performance evaluation. *Advances in Artificial Intelligence*. 4304: 1015-1021. doi: 10.1007/11941439\_144.
- Sari PR, Supijatno. 2015. Pengelolaan pembibitan karet (*Hevea brasiliensis* Muel Arg.) di Balai Penelitian Sembawa, Palembang, Sumatera Selatan. *Buletin Agrohorti*. 3(2):252–262. doi:10.29244/agrob.v3i2.15031.
- Silalahi BJ, Feryandi FTH, Sidabutar P. 2021. Pemanfaatan teknologi citra satelit dan drone untuk pengelolaan pertanahan di wilayah perbatasan Indonesia. *Jurnal Pertanahan*. 11(1):12–22. doi: 10.53686/jp.v11i1.12.
- Sodjinou SG, Mohammadi V, Mahama ATS. 2021. A deep semantic segmentation-based algorithm to segment crops and weeds in agronomic color images. *Information Processing in Agriculture*. 9(3): 355-364. doi: 10.1016/j.inpa.2021.08.003.
- Suta IBLM, Sudarma M, Kumara INS. 2020. Segmentasi tumor otak berdasarkan magnetic resonance imaging dengan menggunakan metode u-net. *Majalah Ilmiah Teknologi Elektro*. 19(2): 151-156. doi: 10.24843/MITE.v19i02.P05.
- Syarifa LF, Agustina DS, Alamsyah A, Nugraha IS, Asywadi H. 2023. Outlook komoditas karet alam indonesia 2023. *Jurnal Penelitian Karet*. 41(1):47-58. doi: 10.22302/ppk.jpk.v41i1.841.





## RIWAYAT HIDUP

Penulis lahir di kota Cilegon pada 26 Januari 2000 sebagai anak ke empat dari pasangan bapak Soderi dan ibu Juleha. Setelah menyelesaikan pendidikan sekolah menengah atas (SMA) di SMAN 1 Cilegon dan lulus pada tahun 2018, penulis diterima sebagai mahasiswa program sarjana (S-1) di Departemen Ilmu Komputer di Institut Pertanian Bogor (IPB) pada tahun 2019. Selama mengikuti program S-1, penulis aktif terlibat sebagai *officer* di IEEE Student Branch IPB, serta bergabung dalam *machine learning cohort* Bangkit Academy 2023 dan menjadi asisten praktikum mata kuliah pengolahan citra digital.

Hak Cipta Dilindungi Undang-undang

1. Dilarang mengutip sebagian atau seluruh karya tulis ini tanpa mencantumkan dan menyebutkan sumber :
  - a. Pengutipan hanya untuk kepentingan pendidikan, penelitian, penulisan karya ilmiah, penyusunan laporan, penulisan kritik atau tinjauan suatu masalah
  - b. Pengutipan tidak merugikan kepentingan yang wajar IPB University.
2. Dilarang mengumumkan dan memperbanyak sebagian atau seluruh karya tulis ini dalam bentuk apapun tanpa izin IPB University.